

Fahrzeugbalance-Vorhersage im Motorsport: Entwicklung und Evaluation von Gradient-Boosting-Modellen auf Basis von Porsche LMDh Telemetriedaten

2. Projektarbeit

vorgelegt am 24.11.2025

Fakultät Wirtschaft und Gesundheit

Studiengang Wirtschaftsinformatik

Kurs WWI2023A

von

JO IMPING

Betreuung in der Ausbildungsstätte:

Dr. Ing. h.c. F. Porsche AG
Paul, Stiegele
IT Product Manager

DHBW Stuttgart:

Prof. Dr. Alexander Brandt

Unterschrift



PORSCHE



Sperrvermerk

Die vorliegende Projektarbeit enthält zum Teil Informationen, die nicht für die Öffentlichkeit bestimmt sind. Während einer Sperrzeit von 5 Jahren ab dem Abgabedatum liegt das alleinige Recht zur Verwertung, insbesondere zur Verbreitung der Projektarbeit, auch auf elektronischen Medien, bei der Dr. Ing. h.c. F. Porsche AG.

Während dieser Sperrzeit darf die Projektarbeit - sei es in Teilen oder als Ganzes - nur mit der ausdrücklichen schriftlichen Genehmigung der Dr. Ing. h.c. F. Porsche AG an Dritte weitergegeben werden.

Die vorliegende Projektarbeit ist zur Vorlage zur Anerkennung der Prüfungsleistung freigegeben.

Stuttgart, den 29.10.2025

A handwritten signature in blue ink, appearing to read "Friedemann".

Unterschrift Fachabteilungsleiter

Inhaltsverzeichnis

Abkürzungsverzeichnis	III
Abbildungsverzeichnis	IV
Tabellenverzeichnis	V
1 Einleitung	1
1.1 Problemstellung	1
1.2 Zielsetzung	2
1.3 Forschungsansatz und Aufbau der Arbeit	2
2 Theoretische Grundlagen	3
2.1 Design Science Research Methodik	3
2.2 Experteninterviews zur Anforderungsermittlung	4
2.3 Maschinelles Lernen für Regressionsprobleme	5
2.4 Gradient Boosting Decision Trees	6
2.5 Hyperparameter-Optimierung und Modellvalidierung	7
2.6 Evaluationsmetriken für Regression	8
3 Anforderungsanalyse und Problemdefinition	9
3.1 Problemdomäne und Use-Case-Identifikation	9
3.2 Anforderungsableitung	10
3.3 Abgrenzung des Design Science Research Artefakts	10
3.4 Forschungsfragen	11
4 Artefakt-Design und Entwicklung	12
4.1 Datensammlung und Analyse	12
4.2 Datenvorbereitung und Feature-Engineering	16
4.2.1 Ableitung der Vorverarbeitungsanforderungen	16
4.2.2 Datenbereinigung und Filterung	17
4.2.3 Feature-Engineering und Dimensionsreduktion	18
4.2.4 Zielvariablen-Glättung	19
4.2.5 Datensatz-Aufteilung und Validierungsstrategie	20
4.2.6 Technische Implementierung	21
4.3 Modelltraining und Hyperparameter-Optimierung	21
4.4 Validierung und Modellvergleich	23
5 Evaluation und Interpretation des Vorhersagemodells	24
5.1 Evaluationskonzept und -methodik	24
5.2 Quantitative Leistungsanalyse	25
5.2.1 Modell-Performance auf Zufalls-Validierungsdatensätzen	25
5.2.2 Modell-Performance auf Event-Validierungsdatensätzen	26
5.2.3 Interpretation des Gesamtergebnisses	28
6 Fazit, Erkenntnisse und Forschungsausblick	30
6.1 Erfüllung der Anforderungen und Beantwortung der Forschungsfragen	30

6.2	Beantwortung der Forschungsfragen	31
6.3	Design Knowledge und kritische Selbsteinschätzung	32
	Anhang	33
	Literaturverzeichnis	47

Abkürzungsverzeichnis

DSR	Design Science Research
EDA	Explorative Datenanalyse
GBDT	Gradient Boosting Decision Trees
IMSA	International Motor Sports Association
KQL	Kusto Query Language
LMDh	Le Mans Daytona hybrid
MAE	Mean Absolute Error
ML	Machine Learning
MSE	Mean Squared Error
RMSE	Root Mean Squared Error
SVR	Support Vector Regression
WEC	World Endurance Championship

Abbildungsverzeichnis

1	Plot der Zielvariable aUndersteer_AVG.	14
2	Plot der Reifentemperatur hinten-rechts.	14
3	Plot des Reifendrucks vorne-links.	15
4	Korrelationsmatrix der 15 am stärksten korrelierten Parameter.	16

Tabellenverzeichnis

1	Übersicht der verwendeten Features und deren Channel-Namen	13
2	Domänenbasierte Schwellwerte für Ausreißererkennung	18
3	Algorithmus-Vergleich: Zufalls-Validierung (alle Komplexitätsstufen)	25
4	Zufalls-Validierung: Performance nach Hyperparameter-Komplexitätsstufe	26
5	Zufalls-Validierung: Effekte der Datensatzstruktur-Varianten	26
6	Algorithmus-Vergleich: Event-Validierung (alle Komplexitätsstufen)	27
7	Event-Validierung: Performance nach Hyperparameter-Komplexitätsstufe	27
8	Event-Validierung: Effekte der Datensatzstruktur-Varianten	28

1 Einleitung

Die vorliegende Arbeit adressiert ein praktisches Problem an der Schnittstelle von Motorsport-Ingenieurwesen und Datenanalyse. Telemetriedaten stehen in großem Umfang verfügbar, werden aber überwiegend manuell analysiert. Dieses Kapitel beschreibt die Notwendigkeit einer automatisierten Fahrzeugbalance-Vorhersage und etabliert die zentralen Forschungsmotivation, die diese Arbeit im Kontext der Design Science Research Methodik beantworten wird. Es bildet damit den Relevance Cycle des Design Science Research (DSR)-Prozesses und verankert die nachfolgenden Kapitel in einer klar definierten Problemdomäne.

1.1 Problemstellung

Der Motorsport ist ein hochkompetitives Umfeld, in dem Verbesserungen der Fahrzeugperformance oft nur Bruchteile von Sekunden bringen, aber entscheidend sind. Moderne Rennfahrzeuge sind mit Tausenden von Sensoren ausgestattet, die kontinuierlich Telemetriedaten erfassen und übertragen. Diese Datenmengen ermöglichen eine beispiellose Sichtbarkeit in Fahrzeugverhalten, Streckenbedingungen und Fahrdynamik. Trotz dieser technologischen Verfügbarkeit verlässt sich die Telemetrie-Analyse in der Praxis stark auf manuelle Prozesse: Renningenieur*innen sichten Dashboards, identifizieren Auffälligkeiten und leiten daraus Anpassungen der Rennstrategie oder des Fahrzeug-Setups ab. Dies ist zeitintensiv und anfällig für Übersehungen subtiler Muster, die erst bei Kombination mehrerer Parameter sichtbar werden. Diese Situation repräsentiert ein klassisches Problem: Ein großes Datenvolumen, klare Geschäftsziele, aber unzureichende Automatisierung zur systematischen Mustererkennung. Machine Learning (ML) verspricht hier die Fähigkeit, aus historischen Daten Muster zu erkennen und auf neue Situationen zu generalisieren.

Die Fahrzeugbalance ist eine Schlüsselgröße für Rennfahrer*innen und Renningenieur*innen. Sie beschreibt die Tendenz des Fahrzeugs, in Kurvenfahrt weniger oder stärker zu lenken als vom Fahrer über das Lenkrad eingegeben. Die Fahrzeugbalance beeinflusst direkt Fahrbarkeit, Sicherheit und Renngeschwindigkeit. Die Balance hängt von zahlreichen, komplex verflochtenen Einflussfaktoren ab. Das zentrale Problem besteht darin, dass Renningenieur*innen diese Zusammenhänge derzeit nicht systematisch erfassen. Sie können nicht vorhersagen, welche spezifischen Parameterkombinationen zu welchen Balance-Änderungen führen. Dies zwingt sie zu reaktivem Handeln: Erst wenn Abweichungen in den Daten offensichtlich werden, werden Anpassungen vorgenommen. Ein proaktiver, vorhersagender Ansatz wäre wertvoll, da er die Fähigkeit bietet, frühzeitig zu signalisieren, dass sich die Balance-Charakteristik verschiebt und damit Setup-Optimierungen vorzeitig zu planen.

Damit ergibt sich die zentrale Forschungsmotivation: Können ML-Modelle aus Telemetriedaten lernen, die Fahrzeugbalance vorherzusagen? Und wenn ja, unter welchen Bedingungen generali-

sieren diese Modelle zuverlässig auf neue Renn-Events mit veränderten Kontexten? Die daraus folgenden Forschungsfragen werden in Kapitel 3.4 präzisiert.

1.2 Zielsetzung

Diese Arbeit verfolgt das Ziel, ein ML-Modell zur Vorhersage der Fahrzeugbalance auf Basis aggregierter Telemetrie-Metriken zu entwickeln und systematisch zu evaluieren. Das Modell soll dazu dienen, Renningenieur*innen zu unterstützen, indem es automatisiert Vorhersagen liefert, anstatt dass Ingenieur*innen manuell Daten analysieren müssen.

Die Entwicklung folgt der DSR Methodik, die in Kapitel 2 eingeführt wird. Dies bedeutet konkret: (1) Systematische Anforderungsanalyse aus der Anwendungsdomäne, (2) Rigorous Build des Artefakts, (3) Umfassende Evaluierung anhand wissenschaftlicher Metriken, und (4) Reflexion von Design Knowledge für die Wissensbasis.¹

1.3 Forschungsansatz und Aufbau der Arbeit

Die vorliegende Arbeit strukturiert sich in sechs Kapitel, die den DSR-Prozess vom Problem zur Lösung abbilden. Kapitel 2 vermittelt die theoretischen Grundlagen, Kapitel 3 analysiert Anforderungen, Kapitel 4 dokumentiert das Design und die Entwicklung des Artefakts, Kapitel 5 evaluiert das Modell-Artefakt und Kapitel 6 schließt den DSR-Zyklus mit Reflexion und Ausblick.

Diese Arbeit verbindet technische Artefakt-Entwicklung mit methodisch fundierter Evaluation. So wird das entwickelte ML-Modell anhand etablierter Metriken bewertet und die gewonnenen Erkenntnisse tragen zur Wissensbasis über ML-Anwendungen im Motorsport bei.

¹Vgl. Hevner et al. 2004, S. 82 ff.

2 Theoretische Grundlagen

Zur Entwicklung eines ML-Modells für Motorsport-Telemetrie-Vorhersage müssen mehrere ineinandergreifende Konzepte verstanden werden. Dieses Kapitel vermittelt zunächst methodische Grundlagen zu Design Science Research und Experteninterviews, dann die Theorie von Regressionsproblemen und speziell Gradient Boosting Decision Trees, und abschließend praktische Aspekte von Optimierung und Validierung. Diese Grundlagen bilden die wissenschaftliche Basis für die in Kapitel 4 beschriebene Artefakt-Entwicklung.

2.1 Design Science Research Methodik

DSR ist ein etablierter Forschungsansatz, der sich grundlegend von deskriptiven Forschungsmethoden unterscheidet. Während traditionelle empirische Forschung primär darauf ausgerichtet ist, bestehende Phänomene zu verstehen und zu erklären, zielt DSR darauf ab, praktische Probleme durch systematische Entwicklung und rigorose Evaluierung von Artefakten zu lösen. Damit schafft DSR eine Brücke zwischen wissenschaftlicher Fundierung und praktischer Problemlösung.²

Das Grundwerk von Hevner et al. (2004) prägt bis heute das Verständnis von DSR und etabliert ein Framework, das auf drei ineinandergreifenden Zyklen basiert:³

Der *Relevance Cycle* beginnt mit Problemidentifikation aus der Anwendungsdomäne; der *Rigor Cycle* verankert die Entwicklung in wissenschaftlichem Wissen und etablierten Theorien; der *Design Cycle* orchestriert iterative Phasen von Artefakt-Konzeption, Entwicklung und Evaluierung. Diese drei Zyklen ermöglichen eine systematische und nachvollziehbare Forschungsvorgehensweise, bei der wissenschaftliche Strenge nicht auf Kosten von Praxisrelevanz geht.

Operationalisiert wird dieser Zyklus-Framework durch sechs sequenzielle *Phasen*, die das praktische Vorgehen konkretisieren:⁴

1. **Problem Identification and Motivation:** Analyse der Problemdomäne und Begründung ihrer wissenschaftlichen und praktischen Relevanz.
2. **Definition of Objectives:** Spezifizierung der Anforderungen, die das entwickelte Artefakt erfüllen muss.
3. **Design and Development:** Konzeption und prototypische Implementierung des Artefakts.

²Vgl. Hevner et al. 2004, S. 82

³Vgl. Hevner et al. 2004, S. 82 ff.

⁴Vgl. Hevner et al. 2004, S. 90.

4. **Demonstration:** Nachweis, dass das Artefakt das Problem tatsächlich lösen kann, typischerweise durch Fallstudien oder kontrollierte Szenarien.
5. **Evaluation:** Systematische Bewertung des Artefakts gegen die vordefinierten Anforderungen und Ziele.
6. **Communication:** Mitteilung von Erkenntnissen und Design Knowledge an die wissenschaftliche Gemeinschaft.

Diese sechs Phasen laufen gleichzeitig in den drei Zyklen ab: Der Relevance Cycle informiert die Problemidentifikation (Phase 1), der Design Cycle orchestriert die Phasen 2–5 iterativ, und der Rigor Cycle durchzieht alle Phasen mit wissenschaftlicher Strenge.

Artefakte in DSR können verschiedene Formen annehmen. Constructs sind konzeptionelle Vokabularien und Abstraktionen, die Probleme präzise definieren. Models stellen Zusammenhänge und Strukturen in vereinfachter Form dar. Methods sind Algorithmen und systematische Verfahrensweisen zur Problemlösung. Instantiations schließlich sind konkrete Implementierungen oder Prototypen.⁵ In ML-Projekten ist die Instantiation typischerweise ein trainiertes Modell mit vollständiger Pipeline (Datenvorverarbeitung, Feature Engineering, trainierte Parameter). Die vorliegende Arbeit entwickelt eine Instantiation: ein evaluiertes ML-Modell für Fahrzeugbalance-Vorhersage.

Die Evaluierung in DSR erfüllt mehrere funktionale Rollen. Sie stellt fest, ob und inwieweit das Artefakt die definierten Anforderungen erfüllt. Sie identifiziert Verbesserungspotenziale für weitere Iterationen. Vor allem trägt sie zur wissenschaftlichen Wissensbasis bei, indem Design Principles und generalisierbare Lessons Learned dokumentiert werden.⁶ Bewährte Evaluationsmethoden in DSR sind observational (Feldbeobachtung), analytical (logische Deduktion und Proof-of-Concept), experimental (kontrollierte Experimente mit Baseline-Vergleich), testing (systematische Funktionsprüfung) und descriptive (qualitative Bewertung durch Experten).⁷ Für ML-Artefakte dominieren analytische und experimentelle Evaluationen mittels etablierter Performance-Metriken.⁸

2.2 Experteninterviews zur Anforderungsermittlung

Die Anforderungsanalyse in Kapitel 3 basiert auf zwei informellen Gesprächen mit einer erfahrenen Renningenieur*in aus dem Porsche Motorsport-Team. Das erste Gespräch fand am 29.08.2025 statt, das zweite am 12.09.2025. Ziel war es, durch offene Diskussion die tägliche Arbeitsweise der Renningenieur*innen nachzuvollziehen, zentrale technische Herausforderungen zu identifizieren und realistische Anforderungen an ein Vorhersagemodell zu formulieren. Die interviewte

⁵Vgl. Hevner et al. 2004, S. 82 ff.

⁶Vgl. Venable, Pries-Heje, Baskerville 2016, S. 79 ff.; vgl. dazu auch Gregor, Jones 2007, S. 322 ff., sowie Hevner et al. 2004, S. 84 f.

⁷Vgl. Hevner et al. 2004, S. 85 f.

⁸Vgl. Friedman, J., Hastie, Tibshirani 2009, S. 219 ff.

Expert*in agiert als Teamleiter*in der Performance-Abteilung im Porsche Le Mans Daytona hybrid (LMDh)-Programm und ist verantwortlich für die Fahrzeugentwicklung, Simulationsmodellierung und insbesondere die datenbasierte Optimierung des Rennwagen-Setups während des operativen Betriebs, wodurch sie über tiefgehendes, direkt anwendbares Wissen im Telemetrie-Management verfügt.⁹ Beide Gespräche folgten einem offenen, exploratorischen Format ohne strukturierten Fragenkatalog, um eine natürliche Konversation zu fördern und implizites Wissen der Expert*in zugänglich zu machen.¹⁰ Die gewonnenen Erkenntnisse bestätigten, dass die aktuelle Telemetrie-Analyse stark manuell erfolgt. Dies validierte die Problemrelevanz und leitete die Anforderungsableitung in Kapitel 3.¹¹

2.3 Maschinelles Lernen für Regressionsprobleme

Maschinelles Lernen (ML) beschreibt die Fähigkeit von Algorithmen, aus Beispieldaten Muster zu erkennen und daraus Vorhersagemodelle zu erstellen, ohne dass die Regeln explizit programmiert werden müssen.¹² In diesem Projekt geht es darum, aus Telemetriedaten eines Fahrzeugs eine kontinuierliche Zielgröße vorherzusagen: den Fahrzeugbalance-Wert. Dies ist ein typisches Regressionsproblem, bei dem die Zielvariable nicht diskret (wie bei einer Klassifikation), sondern stetig ist.¹³ Regressionsmodelle gehören zum überwachten Lernen: Für jede Trainingsinstanz ist der korrekte Zielwert bekannt. Das Modell lernt, diesen Wert aus den Eingabedaten zu rekonstruieren und soll später auch auf neue, unbekannte Daten verallgemeinern können. Damit ein Modell erfolgreich lernen kann, ist die Datenvorbereitung entscheidend. Sie beginnt mit einer explorativen Datenanalyse (EDA), bei der die Rohdaten zunächst gesichtet werden, um Verteilungen, Korrelationen und potenzielle Ausreißer zu erkennen.¹⁴ Darauf folgt die Datenbereinigung, bei der fehlende Werte durch Imputation oder Ausschluss behandelt, fehlerhafte Messungen entfernt und sachlogische Schwellenwerte gesetzt werden, etwa zur Filterung unplausibler Sensorwerte.¹⁵ Im nächsten Schritt erfolgt das Feature Engineering, bei dem die Rohdaten in aussagekräftige Eingabemerkmale transformiert werden. Relevante Features werden gezielt ausgewählt, um Overfitting zu vermeiden und die Trainingszeit zu reduzieren.¹⁶ Hochkorrelierte Sensoren können zu aggregierten Merkmalen zusammengefasst werden, etwa durch Mittelwertbildung mehrerer Temperaturmessungen. Kategoriale Variablen wie Streckenkennungen werden durch Encoding in numerische Form überführt.¹⁷ Für Telemetriedaten ist zudem eine Glättung von Zeitreihen sinnvoll, beispielsweise durch gleitende Mittelwerte, um hochfrequentes Rauschen zu reduzieren und echte physikalische Trends von Messfehlern zu unterscheiden.¹⁸

⁹Vgl. Experteninterview 1, 29.08.2025, Z. 3-27

¹⁰Vgl. Döringer 2021, S. 2 ff.

¹¹Vgl. Experteninterview 1 und 2, dokumentiert in Anhang A.1

¹²Vgl. Mitchell 1997, S. 1 f.

¹³Vgl. Hastie, Tibshirani, Friedman, J. 2009, S. 1 ff.

¹⁴Vgl. Tukey 1977, S. 125 ff.

¹⁵Vgl. Kuhn, Johnson 2019, S. 20 ff.

¹⁶Vgl. Guyon, Elisseeff 2003, S. 1157 ff.

¹⁷Vgl. Kuhn, Johnson 2019, S. 139 ff.

¹⁸Vgl. Box et al. 2015, S. 25 ff.; vgl. dazu auch Cleveland 1979, S. 829 ff.

Nach der Datenvorbereitung stellt sich die Frage, welche Modellklasse für das Problem geeignet ist. Im nächsten Abschnitt wird die Methode der Gradient Boosting Decision Trees (GBDTs) vorgestellt, die sich besonders gut für strukturierte Telemetriedaten eignet und typische Anforderungen des vorliegenden Problems adressiert.

2.4 Gradient Boosting Decision Trees

Gradient Boosting Decision Trees (GBDT) sind eine Ensemble-Methode, die sequenzielle schwache Lerner, das heißt einfache Decision Trees, zu einem starken Vorhersagemodell kombiniert.¹⁹ Das Kernprinzip ist Residual Learning: Der erste Baum wird auf die Rohdaten trainiert. Der zweite Baum wird trainiert, um die Fehler des ersten Baums vorherzusagen, die sogenannten Residuen. Der dritte Baum korrigiert dann die kombinierten Fehler von Baum 1 und 2, und so weiter. Die finale Vorhersage ergibt sich aus einer gewichteten Summe aller Baum-Ausgaben. Formalisiert wird dies durch Gradient Descent: Eine Loss-Funktion, typischerweise Mean Squared Error für Regression, quantifiziert, wie schlecht die Vorhersagen sind. Jeder neue Baum wird so konstruiert, dass er in Richtung des negativen Gradienten dieser Loss-Funktion läuft, also gezielt Fehler reduziert.²⁰ Dieser Gradient-Ansatz führt zu schnellerer Konvergenz als alternatives Ensemble-Averaging.

Gradient Boosting Decision Trees (GBDTs) haben sich als besonders geeignet für Regressionsprobleme erwiesen.²¹ Sie erfassen nichtlineare Zusammenhänge zwischen Eingabemerkmalen und Zielvariable, was über klassische lineare Modelle hinausgeht.²² Gleichzeitig funktionieren sie effizient auf Datensätzen moderater Größe, im Gegensatz zu neuronalen Netzen, die oft große Datenmengen benötigen.²³ GBDTs sind zudem vergleichsweise schnell zu trainieren und bieten Interpretierbarkeit durch Feature-Importance-Schätzungen, die aufzeigen, welche Telemetrie-Signale besonders stark zur Vorhersage der Fahrzeugbalance beitragen.²⁴

Zwei verbreitete Implementierungen von Gradient Boosting sind XGBoost und LightGBM.²⁵ Beide verfolgen dasselbe Grundprinzip, sequenzielles Trainieren von Bäumen zur Fehlerkorrektur, unterscheiden sich aber in technischen Details und Optimierungen.

XGBoost ist eine etablierte und vielseitige Bibliothek, die sich durch robuste Regularisierung und gute Performance auszeichnet.²⁶ LightGBM wurde später entwickelt und ist besonders auf Geschwindigkeit und Effizienz bei großen Datensätzen ausgelegt.²⁷

¹⁹Vgl. Friedman, J. H. 2001, S. 1189 ff.

²⁰Vgl. Friedman, J. H. 2001, S. 1200 ff.

²¹Vgl. Friedman, J. H. 2001, S. 1189 ff.; vgl. dazu auch Chen, Guestrin 2016, S. 785 ff.

²²Vgl. Hastie, Tibshirani, Friedman, J. 2009, S. 58 ff.

²³Vgl. Goodfellow, Bengio, Courville 2016, S. 164 ff.

²⁴Vgl. Chen, Guestrin 2016, S. 788 ff.

²⁵Vgl. Chen, Guestrin 2016, S. 785 ff.; vgl. dazu auch Ke et al. 2017, S. 3146 ff.

²⁶Vgl. Chen, Guestrin 2016, S. 785 ff.

²⁷Vgl. Ke et al. 2017, S. 3146 ff.

Beide Tools sind für strukturierte Daten geeignet und haben sich in der Praxis bewährt. Die konkrete Wahl hängt vom Anwendungsfall ab und wird im folgenden Kapitel diskutiert. Empirisch zeigen beide Implementierungen überlegene Performance auf strukturierten tabularen Daten im Vergleich zu tiefen neuronalen Netzen.²⁸ Die Wahl zwischen ihnen ist oft pragmatisch: XGBoost für Balance, LightGBM wenn Geschwindigkeit kritisch ist.

2.5 Hyperparameter-Optimierung und Modellvalidierung

Um ein GBDT-Modell zu trainieren, müssen vor dem Training viele Hyperparameter gesetzt werden. Hyperparameter unterscheiden sich fundamental von Modell-Parametern, den internen Gewichten des Modells, die während Training gelernt werden. Hyperparameter sind konfigurierbare Stellschrauben, die Entwickler*innen vor dem Training definieren und die das Lernverhalten des Algorithmus steuern.²⁹

Für GBDT sind mehrere Hyperparameter besonders wichtig: Die Anzahl der Estimators bestimmt, wie viele Bäume insgesamt trainiert werden, während die Learning Rate als Schrittweite beim Gradientenverfahren fungiert, wobei kleine Werte zu langsameren, stabileren Verbesserungen, große Werte zu schnellerem, aber riskanterem Lernen führen. Die Max Depth definiert die maximale Tiefe jedes Baums und erhöht mit steigenden Werten die Modellkomplexität. Das Min Child Weight (bzw. die Mindestanzahl an Samples pro Blatt) bewirkt bei höheren Werten konservativere Splits und damit weniger Overfitting, während Subsample den Anteil der Trainingsinstanzen pro Baum festlegt. Schließlich kontrollieren Regularisierungsparameter wie L2-Penalisierung die Modellkomplexität.³⁰ Da manuelle Anpassung dieser Parameter ineffizient ist, nutzt man systematische Hyperparameter-Optimierung. Grid Search definiert ein vorgegebenes Gitter von Parameterwerten und probiert alle Kombinationen systematisch durch, garantiert zwar eine gründliche Suche, führt aber zu exponentiellem Rechenaufwand mit der Anzahl der Parameter.³¹ Nach der Hyperparameter-Optimierung ergibt sich eine weitere zentrale Herausforderung: Generalisiert das Modell auf unbekannte Daten? Diese wird durch Modellvalidierung beantwortet. Der Standard k-fold Cross-Validation partitioniert den Datensatz in k gleiche Teile und trainiert das Modell k-mal, jeweils mit k minus eins Teilen als Training und einem Teil als Validierung. Die gemittelten k Validierungs-Scores geben eine robuste Schätzung der Generalisierungsperformance mit geringerer Varianz als ein einzelner Train-Test-Split.³²

Im vorliegenden Projekt ist jedoch die kritischste Generalisierungsfrage der Transfer auf komplett neue Rennevents, da eine neue Veranstaltung völlig andere Umgebung, andere Fahrer und anderes Setup aufweist. Standard-Cross-Validation löst diese Herausforderung nicht, weshalb hier Leave-One-Out verwendet wird. Dafür wird das Modell auf einem Trainingsdatensatz trainiert,

²⁸Vgl. Chen, Guestrin 2016, S. 788 ff.

²⁹Vgl. Bergstra, Bengio 2012, S. 281 ff.

³⁰Vgl. Chen, Guestrin 2016, S. 787 f.

³¹Vgl. Bergstra, Bengio 2012, S. 281 ff.; vgl. dazu auch Chen, Guestrin 2016, S. 787 f.

³²Vgl. Kohavi 1995, S. 1137 ff.

der alle Veranstaltungen außer einer enthält, und dann auf der zurückgehaltenen Veranstaltung validiert.³³ Dies stellt einen extremen, aber realistischen Stress-Test für echte Domänen-Generalisierung dar und offenbart, ob das Modell echte physikalische Strukturen gelernt hat oder nur Muster des Trainingsdatensatzes memorisiert hat.

Diese drei Komponenten Hyperparameter-Optimierung, Cross-Validation Strategie und Evaluationsmetrik sind untrennbar: Zusammen stellen sie sicher, dass ein entwickeltes Modell tatsächlich verallgemeinerbar ist, nicht nur auf Trainingsdaten overfittet.

2.6 Evaluationsmetriken für Regression

Regressionsergebnisse werden durch mehrere etablierte Fehlermetriken quantifiziert. Der Mean Squared Error (MSE) berechnet den Durchschnitt der quadrierten Abweichungen zwischen Vorhersagen und Ist-Werten und bestraft größere Fehler überproportional. Der Root Mean Squared Error (RMSE) ist die Quadratwurzel des MSE und hat dieselbe Einheit wie die Zielvariable, was die Interpretation erleichtert.³⁴

Der Mean Absolute Error (MAE) quantifiziert den Durchschnitt der absoluten Abweichungen und ist robuster gegenüber Ausreißern, da er Fehler linear (nicht quadratisch) gewichtet.³⁵ Die Wahl zwischen RMSE und MAE sollte sich nach der erwarteten Fehlerverteilung richten: RMSE ist optimal bei normalverteilten Fehlern, MAE bei Laplace-verteilten Fehlern.

Das Bestimmtheitsmaß R^2 (Coefficient of Determination) gibt an, welcher Anteil der Varianz der Zielvariable durch das Modell erklärt wird. $R^2 = 1$ signalisiert perfekte Vorhersagen, $R^2 = 0$ bedeutet, dass das Modell nicht besser als die Mittelwert-Baseline ist. Negative R^2 -Werte sind möglich und deuten auf schlechtere Performance als die Baseline hin.³⁶ In der Ingenieurpraxis und insbesondere im Motorsport-Datenkontext werden für Validierungsmodelle üblicherweise Schwellwerte von $R^2 \geq 0,7$ angestrebt, da dies eine Fehlerreduktion von etwa 50% gegenüber einem Baseline-Modell bedeutet und damit praktische Einsatzfähigkeit gewährleistet.³⁷

Diese drei Metriken (RMSE, MAE, R^2) bilden den internationalen Standard in der Regressionsanalyse und ermöglichen Vergleichbarkeit mit etablierten Benchmarks in der Fachliteratur.

³³Vgl. James et al. 2021, S. 176 ff.

³⁴Vgl. Hodson 2022, S. 5481 f.

³⁵Vgl. Chai, Draxler 2014, S. 1247 ff.

³⁶Vgl. Hastie, Tibshirani, Friedman, J. 2009, S. 10 ff.

³⁷Vgl. O'Donnell et al. 2024, S. 1 ff.

3 Anforderungsanalyse und Problemdefinition

Auf Grundlage der in Kapitel 1 dargestellten Problemstellung werden in diesem Kapitel die konkreten Anforderungen an das zu entwickelnde Artefakt systematisch abgeleitet. Als Basis dafür dienen neben einschlägiger Literatur auch Experteninterviews mit einer Motorsport-Ingenieur*in. Dieses Kapitel konkretisiert die Problemstellung zu spezifischen, messbaren Anforderungen und präzisiert die Forschungsfragen, die als Evaluationskriterien für die später entwickelte Lösung dienen. Damit erfüllt dieses Kapitel die systematische *Definition of Objectives* Phase des DSR-Prozesses.

3.1 Problemdomäne und Use-Case-Identifikation

Im Rahmen dieses Projekts wird mit Telemetriedaten von Porsche LMDh-Rennwagen gearbeitet. LMDh ist eine Fahrzeugklasse für Langstreckenrennen, die in den Weltmeisterschaften International Motor Sports Association (IMSA) und World Endurance Championship (WEC) eingesetzt wird.³⁸

Die Telemetriedaten werden über mehrere Tausend Sensoren in den Rennwagen erfasst und liefern während Trainings- und Rennsessions ununterbrochen Messwerte, die in Echtzeit in die Porsche Motorsport Cloud-Plattform übertragen werden.³⁹ Dort liegen sie als Zeitreihendaten vor und stehen Performance Engineers wahlweise direkt für Detailanalysen zur Verfügung oder werden in Form von Metriken aufbereitet. Unter Metriken versteht man statistische Kennzahlen wie Durchschnitt, Minimum oder Maximum über definierte Zeitabschnitte, zum Beispiel pro Runde oder pro Strecken-Sektion. Diese Metriken bilden die Grundlage, auf der Performance Engineers ihre tägliche Arbeit aufbauen.⁴⁰

Im aktuellen Workflow prüfen Performance Engineers zunächst die Kennzahlen in Dashboards, um Auffälligkeiten zu erkennen. Das können Temperatursprünge in schnellen Kurven sein oder ungewöhnlich hoher Reifenverschleiß auf bestimmten Streckenabschnitten.⁴¹ Allerdings fällt auf, dass diese Auswertung fast ausschließlich manuell erfolgt. Die Ingenieur*innen verbringen pro Rennwochenende mehrere Stunden damit, Metriken zu sichten, Trends zusammenzuführen und in Setup-Empfehlungen zu übersetzen. Das führt nicht nur zu Verzögerungen, sondern birgt auch das Risiko, subtilere Muster zu übersehen, etwa wenn ein Zusammenspiel aus Streckentemperatur, Gas- und Bremsprofil nur in Extremlagen auffällt.⁴²

Die Fahrzeugbalance-Vorhersage ermöglicht einen Wechsel von reaktiver zu vorausschauender Optimierung. Ingenieur*innen könnten Anpassungen bereits dann vornehmen, wenn sich ein

³⁸Vgl. o. V. 2023; vgl. auch o. V. 2025

³⁹Vgl. Experteninterview 2, 12.09.2025, Z. 19-22

⁴⁰Vgl. Experteninterview 2, 12.09.2025, Z. 19-22

⁴¹Vgl. Experteninterview 1, 29.08.2025, Z. 3-27

⁴²Vgl. Experteninterview 1, 29.08.2025, Z. 62-66

akuter Über- oder Untersteuern-Trend ankündigt. Darüber hinaus verspricht dieser Use Case eine objektivere Entscheidungsbasis: Anstelle persönlicher Einschätzungen stünden reproduzierbare Kennzahlenmodelle im Mittelpunkt. Damit würde das bestehende System von punktueller Datenansicht auf datengetriebene Automatisierung übergehen und den Zeitaufwand für Analyse sowie Setup-Änderungen deutlich verringern.⁴³

3.2 Anforderungsableitung

Aus den beiden Experteninterviews mit dem Performance Engineer am 29.08.2025 und 12.09.2025 lassen sich konkrete Anforderungen an das ML-Artefakt ableiten.

Die erste und primäre funktionale Anforderung betrifft die Fähigkeit, die Fahrzeugbalance auf Basis vorhandener Telemetrie-Metriken zuverlässig vorherzusagen. Dieses Ziel folgt direkt aus der Erkenntnis, dass manuelle Analysen mehrere Stunden pro Rennwochenende beanspruchen und dass frühe Hinweise auf Balanceabweichungen häufig erst verspätet offensichtlich werden.⁴⁴ Das Modell soll ohne manuelle Intervention vorhersagen können, welche Fahrzeugbalance-Werte für eine gegebene Kombination von Telemetrie-Inputs zu erwarten sind. Damit wird das Ziel einer automatisierten Fahrzeugbalance-Vorhersage definiert.

Neben der reinen Funktionalität muss das Modell eine hinreichende Vorhersagegenauigkeit aufweisen. In der Fahrzeugtechnik und Ingenieurwissenschaften wird für Validierungsmodelle ein R^2 -Wert von mindestens 0,7 angestrebt, um praktische Einsatzfähigkeit zu gewährleisten.⁴⁵ Unterhalb dieses Schwellenwerts ist die Prognose zu unsicher, um darauf Setup-Entscheidungen zu stützen.

Die dritte Anforderung betrifft die Reproduzierbarkeit und Dokumentation. Eine lückenlose Dokumentation aller Eingangsdaten, Vorverarbeitungsschritte, Modellparameter und Evaluationsergebnisse ist vorgesehen. Nur so kann vollständige Reproduzierbarkeit gewährleistet werden, und die erstellten Prognosen bleiben validierbar.⁴⁶ Diese Anforderung entspricht den Prinzipien der DSR-Methodik, die eine nachvollziehbare Artefakt-Entwicklung fordert.

3.3 Abgrenzung des Design Science Research Artefakts

Das entwickelte Artefakt beschränkt sich auf ein Vorhersagemodell für Fahrzeugbalance-Werte, basierend auf aggregierten Telemetrie-Metriken pro Runde. Diese fokussierte Auslegung ermöglicht es, das Projekt im vorgesehenen Zeitrahmen vollständig durchzuführen.

⁴³Vgl. Experteninterview 2, 12.09.2025, Z. 29-32

⁴⁴Vgl. Experteninterview 1, 29.08.2025, Z. 62-66

⁴⁵Vgl. O'Donnell et al. 2024, S. 1 ff.

⁴⁶Vgl. Venable, Pries-Heje, Baskerville 2016, S. 79

Hinsichtlich der Implementierung arbeitet das Modell auf rundenweise aggregierten Metriken, nicht auf Rohdaten-Sensorströmen. Dies reduziert die Komplexität erheblich und erlaubt fokussiertere Feature-Engineering-Strategien.⁴⁷ Eine Echtzeitvorhersage, die kontinuierlich auf Sensor-Einzelmessungen reagiert, wird damit nicht angestrebt.

Schließlich liefert das Modell keine direkten Setup-Vorschläge, sondern ausschließlich Fahrzeugbalance-Prognosen. Die Ableitung von Setup-Änderungen aus diesen Prognosen bleibt in der Verantwortung der Performance Engineers und wird nicht automatisiert. Damit bleibt die Entscheidungshoheit bei den Ingenieur*innen, während das Modell als Entscheidungsunterstützungssystem fungiert.

Diese Abgrenzung reduziert den Projektumfang auf ein klar definiertes ML-Regressionsproblem und ermöglicht eine fokussierte Evaluation im DSR-Kontext.⁴⁸

3.4 Forschungsfragen

Aus der Problemdefinition und den Anforderungen ergeben sich drei zentrale Forschungsfragen, die das Projekt leiten und in den nachfolgenden Kapiteln beantwortet werden.

Die erste Forschungsfrage adressiert die grundlegende Machbarkeit des Ansatzes: Können Gradient Boosting Decision Trees (GBDT) Fahrzeugbalance-Verhalten in Motorsport-Telemetriedaten vorhersagen? GBDT gelten als state-of-the-art für strukturierte Regressionsprobleme,⁴⁹ aber ihre Anwendbarkeit auf Motorsport-Telemetriedaten ist bisher nicht systematisch untersucht. Diese Frage wird in Kapitel 5 und 6 umfassend beantwortet.

Die zweite Forschungsfrage vergleicht zwei konkrete Algorithmen: Welcher Algorithmus (XGBoost vs. LightGBM) generalisiert besser auf unbekannte Rennevents? Welcher Algorithmus robuster generalisiert, ist unklar und wird durch systematischen Vergleich auf Event-basierten Validierungsdatensätzen beantwortet (Kapitel 5.2).

Die dritte Forschungsfrage konzentriert sich auf die Inputseite des Modells: Wie wirken sich Datenvorbereitung (Feature-Engineering, Glättung, Aggregation) und Hyperparameter-Tuning auf die Vorhersagegenauigkeit aus? Verschiedene Vorverarbeitungsschritte, kategoriale Features, Zielvariablen-Glättung und Hyperparameter-Komplexitätsstufen werden getestet, um ihren Einfluss auf Performance zu quantifizieren (Kapitel 4.2, 4.3, 5.2).

Diese drei Forschungsfragen strukturieren den Aufbau der Arbeit: Kapitel 4 entwickelt das Artefakt systematisch, Kapitel 5 evaluiert es anhand der Forschungsfragen, und Kapitel 6 synthetisiert die Erkenntnisse in Design Knowledge für zukünftige Arbeiten.

⁴⁷Vgl. Kap. 4.2

⁴⁸Vgl. Hevner et al. 2004, S. 83

⁴⁹Vgl. Chen, Guestrin 2016, S. 785 ff.

4 Artefakt-Design und Entwicklung

Die Entwicklung des Artefakts folgte einem strukturierten Prozess, der sicherstellt, dass jede technische Entscheidung sowohl praxisnah als auch wissenschaftlich fundiert ist. In diesem Kapitel werden die Schritte zur Datenvorbereitung, Implementierung der Trainingspipeline und Hyperparameter-Optimierung detailliert diskutiert und begründet.

4.1 Datensammlung und Analyse

Die vorliegende Arbeit nutzt Telemetriedaten aus der Porsche Motorsport Cloud Plattform. Es wurden sämtliche Rennsessions der IMSA- und WEC-Meisterschaften der Jahre 2023 bis 2025 extrahiert. Zur Minimierung von Varianz durch unterschiedliche Fahrsituationen beschränkt sich die Auswahl auf Rennsessions, während Trainings- und Qualifikationssessions ausgeschlossen wurden. Zusätzlich erfolgte eine Filterung auf Runden mit Trockenreifen, da Regenbedingungen weitere Einflussfaktoren einführen. Die Datenselektion wurde direkt beim Abruf mittels der ADX-Kusto Query Language (KQL) vorgenommen, wodurch ein Rohdatensatz im CSV-Format mit 17 735 Runden (Datenpunkten) resultierte.

Im Rahmen eines Experteninterviews mit dem Performance Engineer wurden jene Parameter identifiziert, die als Merkmale (Features) in das ML-Modell eingehen.⁵⁰ Die Merkmale gliedern sich in kontinuierliche und kategoriale Features die in Tabelle-1 aufgelistet sind.

⁵⁰Vgl. Experteninterview 2, 12.09.2025, Z. 37-53

Feature Name	Channel Name	Erklärung
Kontinuierliche Features		
Umgebungstemperatur	TAmbientVms_AVG	Lufttemperatur der Umgebung
Reifentemperatur VL	TTyreIRFLavg	Temperatur des vorderen linken Reifens (Innenrand)
Reifentemperatur VR	TTyreIRFRavg	Temperatur des vorderen rechten Reifens (Innenrand)
Reifentemperatur HL	TTyreIRRLavg	Temperatur des hinteren linken Reifens (Innenrand)
Reifentemperatur HR	TTyreIRRRavg	Temperatur des hinteren rechten Reifens (Innenrand)
Reifendruck VL	pTyreFL_avg	Luftdruck des vorderen linken Reifens
Reifendruck VR	pTyreFR_avg	Luftdruck des vorderen rechten Reifens
Reifendruck HL	pTyreRL_avg	Luftdruck des hinteren linken Reifens
Reifendruck HR	pTyreRR_avg	Luftdruck des hinteren rechten Reifens
Fuel Load	mFuelMass_AVG	Aktuelle Kraftstoffmasse im Tank
Tyre Mileage VL	TyreMilage_FL	Laufleistung des vorderen linken Reifens
Tyre Mileage VR	TyreMilage_FR	Laufleistung des vorderen rechten Reifens
Tyre Mileage HL	TyreMilage_RL	Laufleistung des hinteren linken Reifens
Tyre Mileage HR	TyreMilage_RR	Laufleistung des hinteren rechten Reifens
Reifendruck Asymmetrie	tire_pressure_asymmetry	Asymmetrie zwischen linken und rechten Reifen
Reifendruck Balance	tire_pressure_balance	Balance zwischen Vorder- und Hinterachse
Reifendruck Spread	tire_pressure_spread	Spreizung der Reifendruckwerte
Reifen-Umgebungstemperatur Delta	tire_temp_ambient_delta	Temperaturdifferenz Reifen zu Umgebung
Reifentemperatur Gradient Max	tire_temp_gradient_max	Maximaler Temperaturgradient zwischen Reifen
Kategoriale Features		
Mechanical Balance Front	NDriverARBSettingFAvg	Einstellung der vorderen Stabilisatorsteifigkeit
Mechanical Balance Rear	NDriverARBSettingRAvg	Einstellung der hinteren Stabilisatorsteifigkeit
Brake Balance	rBrakeBiasOffsetRequest_AVG	Bremskraftverteilung Vorder-/Hinterachse
Traction Control Longitudinal	NTCLongitudinal_AVG	Traktionskontrolle längs
Traction Control Lateral	NTCLateral_AVG	Traktionskontrolle quer
Tyre State	NTyreState_AVG	Reifenmischung(hart/medium/soft)
Event Category	eventCategory	Rennstrecke
Zielvariable		
Understeer Average	aUndersteer_AVG	Durchschnittlicher Untersteer-Wert pro Runde

Tab. 1: Übersicht der verwendeten Features und deren Channel-Namen

Als Zielvariable dient der durchschnittliche Fahrzeugbalance-Wert pro Rennrunde (aUndersteer_AVG), wobei Werte über Null Untersteuern und Werte unter Null Übersteuern des Fahrzeugs anzeigen. Dieser Wert wird in der Datenplattform bereits auf Basis physikalischer Formeln berechnet. Diese Berechnung wird aus Umfangsgründen nicht näher erläutert. Alle Parameter und die Zielvariable wurden rundenmittelnd aggregiert, sodass jeder Datensatzpunkt einer einzelnen Rennrunde entspricht. Die Explorative Datenanalyse (EDA) wurde durchgeführt, um die Dateneigenschaften zu untersuchen und potenzielle Datenqualitätsprobleme zu identifizieren. Zunächst wurde die Verteilung der Zielvariable aUndersteer_AVG untersucht.⁵¹

⁵¹Vgl. Tukey 1977, S. 125 ff.




Abb. 1: Plot der Zielvariable aUndersteer_AVG.

Der in Abbildung 1 dargestellte Verlauf des Fahrzeugbalance-Channels ist auffällig, denn obwohl es sich bereits um Durchschnitte über jeweils eine Runde handelt, weist der Graph eine hohe Volatilität auf. Diese Erkenntnis sollte in der Modellierung der Vorverarbeitungsschritte berücksichtigt werden, um die Robustheit des Modells zu erhöhen.

Die Verteilungen der zentralen kontinuierlichen Features wurden ebenfalls untersucht. Abbildung 2 zeigt exemplarisch die Verteilung der Reifentemperatur hinten-rechts. Dabei sind sowohl realistische, aber extreme Werte unter 40 Grad Celsius als auch auffällige, unrealistische Ausreißer über 300 Grad Celsius zu erkennen. Die Einschätzung, ob es sich um valide Daten handelt, erfolgt durch Informationen aus Experteninterviews.⁵² Diese Ausreißer deuten auf potenzielle Sensorfehler oder Datenqualitätsprobleme hin und werden in der Datenvorbereitung entsprechend behandelt.




Abb. 2: Plot der Reifentemperatur hinten-rechts.

⁵²Vgl. Experteninterview 1, 29.08.2025, Z. 97-105

Auch bei den Werten des Reifendrucks gibt es auffällige Ausreißer. Abbildung 3 zeigt die Verteilung des Reifendrucks vorne-links. Hier sind ebenfalls unrealistische Werte zu erkennen, die auf mögliche Datenqualitätsprobleme hinweisen und in der Vorverarbeitung entsprechend berücksichtigt werden müssen.




Abb. 3: Plot des Reifendrucks vorne-links.

Abschließend wurde mittels Korrelationsmatrix die Stärke der Zusammenhänge aller Merkmale untersucht. Dabei ergaben sich insbesondere enge Korrelationen zwischen den Reifentemperatur- und Reifendrucksensoren sowie zwischen der Kraftstoffmenge und der Anzahl der Runden pro Reifenlaufleistung.

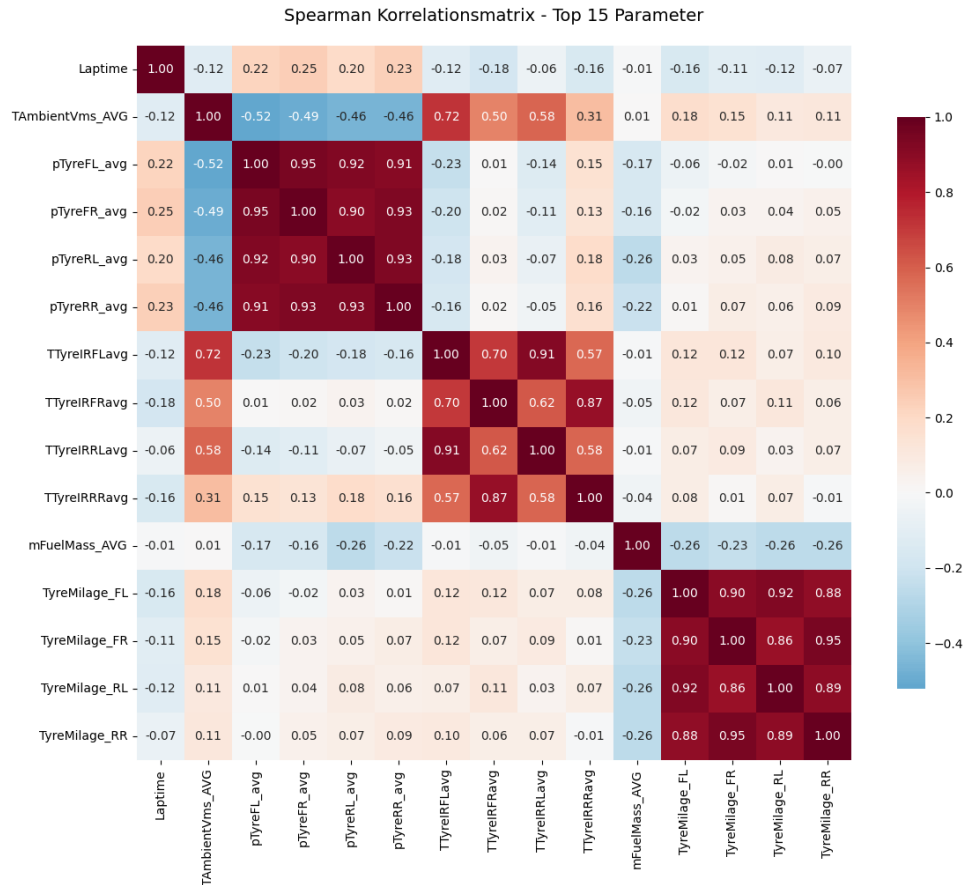


Abb. 4: Korrelationsmatrix der 15 am stärksten korrelierten Parameter.

Die explorative Analyse zeigte (i) stark schwankende Zielgrößen trotz Rundenglättung, (ii) häufige Ausreißer und Sensorartefakte bei Temperatur und Druck, sowie (iii) hohe Redundanzen in korrelierten Messkanälen (Reifen- und Drucksensorik, Fuel Load vs. Tyre Mileage). Im nächsten Abschnitt werden die daraus abgeleiteten Vorverarbeitungsschritte und das Feature-Engineering formalisiert und implementierungsorientiert beschrieben.

4.2 Datenvorbereitung und Feature-Engineering

Basierend auf den EDA-Erkenntnissen werden nachfolgend die systematischen Vorverarbeitungsschritte zur Transformation des Rohdatensatzes in ein trainingstaugliches Format dokumentiert.

4.2.1 Ableitung der Vorverarbeitungsanforderungen

Aus den Erkenntnissen der explorativen Datenanalyse ergeben sich konkrete Anforderungen an die Datenvorbereitung. Die hohe Volatilität der Zielvariable aUndersteer_AVG erfordert Strate-

gien zur Glättung von Zeitreihenschwankungen, da selbst rundenmittelnd aggregierte Werte eine unregelmäßige Verteilung aufweisen. Die identifizierten Sensorartefakte bei Reifentemperaturen über 300 Grad Celsius und unrealistische Werte bei Reifendruckmessungen indizieren Messfehler, die durch domänenbasierte Schwellwertfilterung adressiert werden müssen.⁵³ Ferner zeigt die Korrelationsmatrix aus Abschnitt 4.1 starke Abhängigkeiten zwischen einzelnen Sensoren derselben physikalischen Größe, was eine Reduktion redundanter Features nahelegt.⁵⁴

Diese Anforderungen entsprechen den Design Requirements für das Datenartefakt im Sinne der DSR-Methodik. Die Vorverarbeitungsentscheidungen werden transparent dokumentiert und auf drei Quellen zurückgeführt: (i) datengetriebene Erkenntnisse der EDA, (ii) domänengetriebene Validierung durch Experteninterviews sowie (iii) theoriegetriebene Fundierung durch etablierte ML-Literatur zu Datenvorverarbeitung und Ausreißererkennung.

4.2.2 Datenbereinigung und Filterung

Zur Minimierung systematischer Verzerrungen wurden zunächst alle Out-Laps (Runde = 1) aus dem Datensatz entfernt. Out-Laps weisen typischerweise atypische Charakteristika auf, da Fahrzeuge die Boxengasse verlassen und sich das thermische Verhalten der Reifen von regulären Rennrunden unterscheidet. Diese Filterregel reduziert Varianz durch nicht-repräsentative Datenpunkte und stellt sicher, dass das Modell ausschließlich auf Basis von Rennrunden mit stabilisiertem Fahrzeugverhalten trainiert wird.

Eine weitere Quelle von Varianz sind Extremereignisse während des Rennens, wie Unfälle, Safety-Car-Phasen oder technische Defekte. Diese manifestieren sich in der Regel durch extreme Abweichungen der Rundenzeit vom durchschnittlichen Niveau. Zur Identifikation solcher Ereignisse wurde eine statistische Schwellwertmethode angewendet. Runden, deren Rundenzeit um mehr als eine Standardabweichung (ca. 40 Sekunden) vom Mittelwert abweichen, wurden aus dem Datensatz entfernt. Diese Filterung folgt etablierten statistischen Verfahren zur Ausreißererkennung in Zeitreihendaten und trägt zur weiteren Varianzreduktion bei.⁵⁵

Für die kontinuierlichen Features Reifentemperatur und Reifendruck wurden domänenspezifische Schwellwerte zur Erkennung und Entfernung unrealistischer Messwerte definiert. Wie in Abbildung 2 dargestellt, treten bei Reifentemperaturen Werte über 300 Grad Celsius auf, die physikalisch nicht plausibel sind und auf Sensorfehler hindeuten. Analog zeigen Reifendruckmessungen (Abbildung 3) Ausreißer außerhalb realistischer Bereiche. Die Festlegung der konkreten Grenzwerte erfolgte unter Einbeziehung von Expert*innenwissen.⁵⁶ Dieser domänenbasierte Ansatz zur Ausreißererkennung ist in der ML-Literatur als effektive Methode etabliert, wenn technisches Fachwissen verfügbar ist.⁵⁷ Die Implementierung erfolgte durch Filterregeln, die Datenpunkte außerhalb der definierten Grenzwerte ausschließen.

⁵³Vgl. Experteninterview 2, 12.09.2025, Z. 42-53

⁵⁴Vgl. Guyon, Elisseeff 2003, S. 1165 ff.

⁵⁵Vgl. Box et al. 2015, S. 408 ff.

⁵⁶Vgl. Experteninterview 1, 29.08.2025, Z. 97-105

⁵⁷Vgl. Kuhn, Johnson 2019, S. 73 f.

Feature-Kategorie	Unterer Grenzwert	Oberer Grenzwert
Reifendruck (alle Räder) [bar]	1,3	2,5
Reifentemperatur (alle Räder) [°C]	40	125
Kraftstoffmasse [kg]	0	120

Tab. 2: Domänenbasierte Schwellwerte für Ausreißerererkennung

4.2.3 Feature-Engineering und Dimensionsreduktion

Die in Abschnitt 4.1 präsentierte Korrelationsmatrix (Abbildung 4) offenbart hohe Korrelationen zwischen einzelnen Sensoren der Reifentemperatur sowie des Reifendrucks. Solche redundanten Features können bei ML-Modellen zu Multikollinearität führen und die Interpretierbarkeit reduzieren. Multikollinearität bezeichnet dabei die starke lineare Abhängigkeit zwischen zwei oder mehr unabhängigen Variablen, wodurch deren individuelle Einflussnahme auf die Zielvariable im Modell schwer zu unterscheiden ist.⁵⁸ Zur Quantifizierung der Redundanz wurde ein korrelationsbasiertes Verfahren angewendet: Features mit einer absoluten Pearson-Korrelation über 0,9 zu anderen Features wurden als hochkorreliert klassifiziert.⁵⁹ Die Identifikation dieser Feature-Gruppen bildet die Grundlage für die nachfolgende Feature-Aggregation. Anstatt hochkorrelierte Features vollständig zu entfernen, wurden neue motorsport-relevante Features durch statistische Zusammenfassung der Sensorgruppen erstellt. Aus den vier Reifendruck-Sensoren (vorne-links, vorne-rechts, hinten-links, hinten-rechts) und den entsprechenden Temperatursensoren wurden folgende abgeleitete Features generiert:

- **tire_pressure_asymmetry**: Links-Rechts-Balance ($|FL - RL|$)
- **tire_pressure_balance**: Vorn-Hinten-Balance (Durchschnitt vorne - hinten)
- **tire_pressure_spread**: Setup-Homogenität (max - min aller Drücke)
- **tire_temp_ambient_delta**: Arbeitstemperatur relativ zur Umgebung
- **tire_temp_gradient_max**: Maximales thermisches Ungleichgewicht (max - min Temperaturen)

Diese Transformation reduziert die Dimensionalität bei gleichzeitigem Erhalt der relevanten Information und kann die Modellgeneralisierung verbessern.⁶⁰ Um die Auswirkung dieser Dimensionsreduktion auf die Modellperformance empirisch zu evaluieren, wurden zwei Feature-Konfigurationen erstellt: (i) Datensätze mit aggregierten Features bei gleichzeitigem Entfernen

⁵⁸Vgl. James et al. 2021, S. 107 ff.; vgl. dazu auch Guyon, Elisseeff 2003, S. 1165 ff.; vgl. dazu auch Yu, Liu 2004, S. 1205 ff.

⁵⁹Vgl. Kuhn, Johnson 2019, S. 180 ff.; vgl. dazu auch Hall 1999, S. 51 ff.

⁶⁰Vgl. Guyon, Elisseeff 2003, S. 1158 f.

der hochkorrelierten Original-Features sowie (ii) Datensätze mit aggregierten Features bei Beibehaltung aller Original-Features. Diese experimentelle Designentscheidung ermöglicht eine systematische Bewertung des Trade-offs zwischen Dimensionalität und Informationsgehalt in der späteren Evaluationsphase.

Der Datensatz enthält zudem kategoriale Features wie die Traktionskontroll-Settings und weitere diskrete Variablen (siehe Tabelle 1). Für die Track-Variable wurde eine ordinale Kodierung vorgenommen: Die alphabetisch sortierten Streckennamen wurden numerischen Codes zugeordnet (TrackCode). Diese Zuordnung wurde in einer separaten Mapping-Datei dokumentiert, um die Rückverfolgbarkeit zu gewährleisten und eine konsistente Kodierung zwischen Trainings- und Validierungsdaten sicherzustellen.⁶¹ Eine One-Hot-Encodierung kategorialer Features wurde bewusst nicht durchgeführt, da die in dieser Arbeit verwendeten baumbasierten Modelle XGBoost und LightGBM kategoriale Features, welche im nächsten Abschnitt genau behandelt werden, nativ unterstützen.⁶² Diese Algorithmen implementieren spezialisierte Split-Strategien für kategoriale Variablen, die gegenüber One-Hot-Encodierung Vorteile in Bezug auf Speichereffizienz und Modellperformance bieten.⁶³ Zur Untersuchung des Einflusses kategorialer Features auf die Modellleistung wurden zusätzlich Datensatzvarianten ohne kategoriale Features erstellt. Diese Designentscheidung folgt dem Prinzip der systematischen Evaluation multipler Artefaktvarianten in der Build-Phase der DSR-Methodik.

4.2.4 Zielvariablen-Glättung

Trotz der rundenmittelnd aggregierten Zielvariable `aUndersteer_AVG` zeigt deren zeitlicher Verlauf (Abbildung 1) eine hohe Volatilität. Diese kurzfristigen Schwankungen können durch situative Faktoren wie Verkehrssituationen, Überholmanöver oder kurzzeitige Setup-Änderungen verursacht werden und erschweren die Identifikation längerfristiger Trends im Fahrzeugverhalten. Zur Adressierung dieser Problematik wurde eine Glättungsstrategie mittels gleitender Durchschnitte (Moving Averages) implementiert. Gleitende Durchschnitte sind eine etablierte Methode zur Rauschreduktion in Zeitreihendaten und werden häufig im Feature Engineering eingesetzt.⁶⁴ Die Methode berechnet für jede Runde den Durchschnitt über ein Fenster von n benachbarten Runden, wodurch kurzfristige Fluktuationen gedämpft werden. Um die optimale Fenstergröße zu ermitteln, wurden mehrere Glättungsvarianten mit unterschiedlichen Fenstergrößen erstellt: keine Glättung (Baseline), sowie gleitende Durchschnitte mit Fenstergrößen 2, 3 und 4. Die Wahl dieser Fenstergrößen basiert auf folgender Überlegung: Kleinere Fenster (2, 3) erfassen kurzfristige Schwankungen und erhalten mehr Details, während größere Fenster (4) stärker glätten und langfristige Trends betonen.⁶⁵ Die ungeglättete Variante dient als Referenz zur Quantifizierung des Effekts der Glättung auf die Modellperformance. Diese multiplen Glättungsvarianten stellen alternative Designentscheidungen dar, die im Rahmen der iterativen Build-Evaluate-Phasen der

⁶¹Vgl. Chen, Guestrin 2016, S. 785 ff.

⁶²Vgl. Chen, Guestrin 2016, S. 785 ff.; vgl. dazu auch Ke et al. 2017, S. 3146 ff.

⁶³Vgl. Chen, Guestrin 2016, S. 785 ff.

⁶⁴Vgl. Box et al. 2015, S. 25 ff.

⁶⁵Vgl. Box et al. 2015, S. 35 ff.

DSR-Methodik systematisch evaluiert werden. Die Erstellung mehrerer Varianten ermöglicht eine empirische Bewertung des Trade-offs zwischen Rauschreduktion und Informationsverlust.

4.2.5 Datensatz-Aufteilung und Validierungsstrategie

Die Kombination der beschriebenen Vorverarbeitungsoptionen resultiert in einer systematischen Variation von Datensatzkonfigurationen. Die Designentscheidungen umfassen drei Dimensionen:

1. **Kategoriale Features:** mit kategorialen Features vs. ohne kategoriale Features (2 Varianten)
2. **Feature-Reduktion:** aggregierte Features mit Entfernung hochkorrelierter Original-Features vs. aggregierte Features zusätzlich zu Original-Features (2 Varianten)
3. **Zielvariablen-Glättung:** keine Glättung, Fenstergröße 2, 3, 4 (4 Varianten)

Die vollständige Kombination dieser Dimensionen ergibt $2 \times 2 \times 4 = 16$ Trainingsdatensätze. Jeder Datensatz umfasst nach Anwendung aller Filterungsschritte ca. 9 000 Runden (Datenpunkte).

Die Validierung der entwickelten Modelle erfordert separate Validierungsdatensätze, die während des Trainings nicht zugänglich sind. Um die Generalisierungsfähigkeit der Modelle umfassend zu bewerten, wurden zwei komplementäre Validierungsstrategien implementiert:

Event-basierte Validierung: Ein vollständiges Renn-Event wurde vom Trainingsdatensatz separiert und als Validierungsdatensatz reserviert. Diese Strategie prüft die Fähigkeit des Modells, auf eine neue, ungesehene Kombination von Strecke, Wetterbedingungen und Rennsituation zu generalisieren.⁶⁶ Der Event-Validierungsdatensatz umfasst ca. 200 Runden.

Zufällige Validierung: Aus dem verbleibenden Datensatz wurden 10 % der Runden zufällig ausgewählt und als zweiter Validierungsdatensatz verwendet. Diese Strategie entspricht der etablierten Praxis des Train-Test-Splits in der ML-Literatur und dient der Bewertung der Modellperformance auf typischen, aber ungesehenen Datenpunkten.⁶⁷ Der Zufalls-Validierungsdatensatz umfasst ca. 1 000 Runden.

Für beide Validierungsstrategien wurden Datensätze entsprechend der zwei Feature-Konfigurationen (mit/ohne kategoriale Features) und der zwei Reduktionsstrategien (mit/ohne Entfernung hochkorrelierter Features) erstellt. Dies resultiert in $2 \times 2 \times 2 = 8$ Validierungsdatensätzen. Die zweifache Validierungsstrategie ermöglicht eine differenzierte Robustheitsbewertung: Die Event-basierte Validierung testet die Extrapolationsfähigkeit auf vollständig neue Kontexte, während die zufällige Validierung die Interpolationsfähigkeit innerhalb der Verteilung der

⁶⁶Vgl. James et al. 2021, S. 185 ff.

⁶⁷Vgl. James et al. 2021, S. 32 f.

Trainingsdaten bewertet. Diese Kombination entspricht best practices im ML und erhöht die Aussagekraft der Modellbewertung.⁶⁸

4.2.6 Technische Implementierung

Die beschriebenen Vorverarbeitungsschritte wurden in einem Python-Skript implementiert. Die Pipeline verarbeitet die Rohdaten (17 735 Runden aus der KQL-Extraktion) in einer klar definierten Sequenz: Zunächst werden die Daten eingelesen und unmittelbar um nicht-repräsentative Out-Laps sowie extrem abweichende Rundenzeiten bereinigt. Anschließend entfernt eine domänenbasierte Schwellwertlogik physikalisch unrealistische Sensorwerte. Darauf folgt das Feature-Engineering, in dessen Rahmen hochkorrelierte Sensorkanäle durch aggregierte, informationsverdichtete Kennwerte ersetzt bzw. ergänzt und kategoriale Merkmale ordinal kodiert werden. Im nächsten Schritt erzeugt die Pipeline alternative Zielvarianten durch optionale Glättung (keine, Fenster 2, 3, 4), wodurch parallele Datensatzkonfigurationen für die spätere Modellselektion entstehen. Abschließend werden zwei Validierungsperspektiven vorbereitet: ein vollständig herausgelöstes Renn-Event (Extrapolation) sowie ein zufälliger Anteil von 10 % der verbleibenden Runden (Interpolation). Aus der vollständigen Kreuzung der Vorverarbeitungsoptionen resultieren so 16 Trainingsdatensätze und 8 korrespondierende Validierungsdatensätze, die konsistent im CSV-Format versioniert abgelegt werden.

Die Implementierung stellt Reproduzierbarkeit durch konsistente Transformation aller Datensatzvarianten sicher. Alle Mapping-Dateien und Konfigurationsparameter wurden dokumentiert und versioniert.

Im Kontext der DSR-Methodik stellt dieses Kapitel die Build-Phase der Datenpipeline dar. Die multiplen Datensatzvarianten ermöglichen eine systematische Evaluation der Auswirkungen unterschiedlicher Vorverarbeitungsentscheidungen auf die Modellperformance in der nachfolgenden Evaluate-Phase. Die transparente Dokumentation aller Designentscheidungen mit Rückführung auf EDA-Erkenntnisse, Expert*innenwissen und theoretische Fundierung erfüllt die Rigor-Anforderungen der DSR-Methodik. Die vorbereiteten Datensätze bilden die Grundlage für die Modellentwicklung und Hyperparameter-Optimierung im nachfolgenden Abschnitt 4.3.

4.3 Modelltraining und Hyperparameter-Optimierung

Die Modelltrainingsphase bildet den Kern der Artefakt-Entwicklung und zielt darauf ab, aus den in Abschnitt 4.2 generierten 16 Datensatzstrukturen robuste Vorhersagemodelle abzuleiten. Hierzu werden zwei Gradient-Boosting-Algorithmen (XGBoost und LightGBM) auf vier abgestuften Komplexitätsniveaus mittels systematischer Hyperparameter-Optimierung trainiert und anschließend auf strukturkonsistenten Validierungsdatensätzen evaluiert.

⁶⁸Vgl. James et al. 2021, S. 175 ff.

Neben Gradient Boosting Decision Trees (GBDT) wurden lineare Modelle (Linear, Ridge, Lasso), Support Vector Regression (SVR), Random Forest sowie Deep-Learning-Architekturen (MLP, TabNet) als Alternativen geprüft. Lineare Ansätze erfassen komplexe nichtlineare Zusammenhänge der Telemetriedaten nur begrenzt, SVR skaliert bei 9 000 Runden und fehlender nativer Unterstützung kategorialer Merkmale ungünstig.⁶⁹ Random Forest liefert zwar robuste Baselines, erreicht aber in tabularen Regressionen häufig nicht die Spitzengenauigkeit moderner Boosting-Methoden.⁷⁰ Neuronale Netze zeigen auf mittelgroßen tabularen Datensätzen gegenüber fortgeschrittenem Baum-Boosting Performance-Nachteile.⁷¹ Aus diesen Gründen fokussiert sich das Artefakt auf Gradient-Boosting-Entscheidungsbäume als günstigen Kompromiss aus Prognosegüte, Interpretierbarkeit und Umsetzbarkeit. Zwei komplementäre Implementierungen desselben Paradigmas werden eingesetzt: XGBoost für Regularisierung und Stabilität, LightGBM für Effizienz und Trainingsgeschwindigkeit. Beide können kategoriale Merkmale direkt verarbeiten und reduzieren so Kodierungsaufwand und Komplexität.⁷² Die Parallelnutzung folgt dem DSR-Prinzip vergleichender Evaluation theoretisch fundierter Artefakt-Alternativen.

Die Trainingspipeline führt für jede der 16 Datensatzstrukturen denselben reproduzierbaren Ablauf aus: (i) Einlesen und Aufteilung in Features/Zielvariable, (ii) systematische Hyperparameter-Suche mittels dreifacher Kreuzvalidierung, (iii) Retraining des besten Konfigurationsprofils auf allen Trainingsdaten zur Maximierung der Vorhersagequalität, (iv) strukturierte Persistierung von Modell, Parametern und Metriken (R^2 , RMSE, MAE). Deterministische Zufallssaaten und parallele Ausführung (scikit-learn-kompatible API) gewährleisten Vergleichbarkeit und Reproduzierbarkeit.⁷³

Für die Hyperparameter-Optimierung wird `GridSearchCV` eingesetzt: vollständige Suche über klar abgegrenzte Parameter-Intervalle, primäre Bewertungsmetrik ist R^2 (direkt interpretierbar für Fachexpert*innen), ergänzt durch Fehlermaße zur Einschätzung der Abweichungsgrößenordnung.⁷⁴ Die dreifache Kreuzvalidierung bietet robuste Schätzungen bei vertretbarem Aufwand.

Abgestufte Komplexitätsprofile strukturieren die Suche:

Shallow: `n_estimators`: 50–100, `max_depth`: 3–4, η : 0.1–0.2.

Medium: `n_estimators`: 100–500, `max_depth`: 5–9, η : 0.05–0.1.

Deep: `n_estimators`: 300–700, `max_depth`: 10–12, η : 0.03–0.05.

Very Deep: `n_estimators`: 400–800, `max_depth`: 10–15, η : 0.02–0.03.

Zusätzlich variieren `subsample` (0.8/1.0), `colsample_bytree` (0.8/1.0) bzw. `feature_fraction`, `min_child_weight`/`min_child_samples`.

⁶⁹Vgl. Pasaribu 2024, S. 3 f.

⁷⁰Vgl. o. V. 2024, S. 4 ff.; vgl. dazu auch Hastie, Tibshirani, Friedman, J. 2009, S. 587 ff.

⁷¹Vgl. McElfresh et al. 2023, S. 1 ff.

⁷²Vgl. Chen, Guestrin 2016, S. 785 ff.; vgl. dazu auch Ke et al. 2017, S. 3146 ff.

⁷³Vgl. Pedregosa et al. 2011, S. 2825 ff.

⁷⁴Vgl. Bergstra, Bengio 2012, S. 281 ff.; vgl. dazu auch Pedregosa et al. 2011, S. 2828 f.

Beide Verfahren haben das Ziel, eine quadratische Fehlerfunktion zu minimieren.⁷⁵ L2 ist konsistent mit R^2 , da eine Reduktion der Residuen direkt zu höherer Erklärungsvarianz führt. Gewählt wurde L2 aufgrund (i) Etabliertheit in tabularer Regression, (ii) stabiler Optimierungseigenschaften (glatte Gradienten), (iii) direkter Interpretierbarkeit ergänzender Fehlerkennzahlen (RMSE/-MAE). Alternativen wie Huber- oder Quantile-Loss wurden nicht priorisiert, weil potenzielle Ausreißer bereits vorab bereinigt wurden und zusätzliche Komplexität ohne klaren Mehrwert vermieden wird.

Aus der Kreuzung von 16 Datensatzstrukturen, zwei Boosting-Implementierungen und vier Komplexitätsstufen entstehen **128 trainierte Modelle**.

4.4 Validierung und Modellvergleich

Die abschließende Validierung erfolgt in einem dedizierten Jupyter-Notebook, das die finalen Modelle auf einem zuvor ungesehenen Validierungsdatensatz evaluiert und vergleichbar macht. Dafür wird jedes Modell einzeln geladen und auf beiden Datensätzen (Event und Zufalls-Datensatz) evaluiert. Das Ergebnis sind insgesamt **256 Evaluationsergebnisse** die aus den Evaluationsmetriken R^2 , RMSE und MAE, für jedes Modell bestehen. Dadurch wird transparent, welche Modelltyp-/Feature-Kombination auf neuen, ungesehenen Telemetriedaten am besten generalisiert.

⁷⁵Vgl. Chen, Guestrin 2016 S. 785 ff.; vgl. dazu auch Ke et al. 2017, S. 3146 ff.

5 Evaluation und Interpretation des Vorhersagemodells

Die vorangegangenen Kapitel dokumentierten die systematische Entwicklung von 128 Modellkonfigurationen basierend auf 16 Datensatzstrukturen nach der DSR-Methodik. Das vorliegende Kapitel bildet die Evaluate- und Reflect-Phase des Design Cycle und wertet die Modellperformance systematisch aus sowie interpretiert die Ursachen identifizierter Leistungsgrenzen. Im Kontext der DSR-Methodik müssen drei zentrale Dimensionen nachgewiesen werden: *Utility* (der praktische Nutzen des Modells), *Quality* (die Robustheit und Zuverlässigkeit) sowie *Efficacy* (die Problemlösung und Anforderungserfüllung).⁷⁶

Die Evaluation erfolgt primär als artificial Evaluation durch quantitative Metriken auf strukturalistischen Validierungsdatensätzen.⁷⁷ Eine naturalistic Evaluation durch Expert*innenfeedback wird bewusst nicht in diesem Kapitel durchgeführt, da die Modellperformance auf Event-Validierungsdatensätzen bereits zeigt, dass das Artefakt nicht für produktiven Einsatz geeignet ist. Stattdessen fokussiert die Analyse auf die technische Ursachenforschung, um generalisierbares Design Knowledge für zukünftige ML-Projekte im Motorsport abzuleiten. Die anschließende Interpretation der Evaluationsergebnisse identifiziert die Kernproblematik beobachteter Leistungsgrenzen und schließt damit den Rigor Cycle der DSR-Methodik.

5.1 Evaluationskonzept und -methodik

Die Evaluationsstrategie folgt dem FEDS-Framework und adressiert vier zentrale Fragen:

Warum erfolgt die Evaluation (summativ: abschließende Qualitätsbewertung des Artefakts), **wann** (ex-post nach Modelltraining und -optimierung), **wie** (kombiniert quantitativ und qualitativ, naturalistisch im Praxiskontext) und **was** wird evaluiert (Prädiktionsgenauigkeit, algorithmische Eigenschaften, Datensatzstruktur-Effekte).⁷⁸

Für alle 256 Evaluationsergebnisse (128 Modelle \times 2 Validierungsstrategien je Datensatzstruktur) werden die standardisierten Regressionsmetriken R^2 , MAE und RMSE verwendet, deren Definitionen bereits in Kapitel 2 erläutert wurden.

Diese drei Metriken folgen etablierten Standards in der ML-Literatur.⁷⁹

Die Evaluation untersucht systematisch (i) die Prädiktionsgenauigkeit auf beiden Validierungsdatensatz-Typen (Generalisierung vs. Robustheit), (ii) den Vergleich zwischen LightGBM und XGBoost, (iii) die Effekte der vier Hyperparameter-Komplexitätsstufen und (iv) die Auswirkungen von Glättung, Feature-Reduktion und kategorialen Features auf die Performance.

⁷⁶Vgl. Venable, Pries-Heje, Baskerville 2016, S. 77 ff.

⁷⁷Vgl. Venable, Pries-Heje, Baskerville 2016, S. 77 ff.

⁷⁸Vgl. Venable, Pries-Heje, Baskerville 2016, S. 77 ff.

⁷⁹Vgl. Hodson 2022, S. 5481 ff.; vgl. dazu auch Willmott, Matsuura 2005, S. 79 f.

5.2 Quantitative Leistungsanalyse

Die Evaluation der 128 trainierten Modelle auf zwei strukturkonsistenten Validierungsdatensätzen zeigt eine stark zweigeteilte Leistungslandschaft, die erhebliche Implikationen für die praktische Einsatzfähigkeit des Artefakts hat. Im Folgenden werden zunächst die positiven Ergebnisse auf dem Zufalls-Validierungsdatensatz dargestellt, anschließend die kritischen Befunde der Event-basierten Validierung erörtert und abschließend die Generalisierungsproblematik analysiert. Die kompletten Ergebnisse der Validierung sind im Anhang 2 dokumentiert.

5.2.1 Modell-Performance auf Zufalls-Validierungsdatensätzen

Die Zufalls-Validierung gibt Aufschluss über die Modellqualität auf typischen, aber ungesesehenen Daten innerhalb der trainierten Verteilung. Die Ergebnisse sind substantiell positiv und zeigen, dass das entwickelte Artefakt unter Standardbedingungen akzeptable Vorhersagefähigkeit aufweist. Durchschnittlich erreicht das Modellportfolio eine R^2 von 0.308 (± 0.197), mit einer Range von -0.338 bis 0.657 . Dies bedeutet, dass das durchschnittliche Modell etwa ein Drittel der Varianz in der Zielvariable erklären kann. Die mittlere RMSE-Abweichung liegt bei 0.328 (± 0.049), was einer durchschnittlichen Vorhersageabweichung von etwa 0.33 Understeer-Einheiten entspricht.⁸⁰ Damit liegen die Modelle in der praktischen Größenordnung, die für Engineering-Fragestellungen relevant ist. XGBoost dominiert deutlich die Zualls-Validierungsperformance mit einem Durchschnitts- R^2 von 0.380 (± 0.235), während LightGBM mit 0.237 (± 0.112) deutlich dahinter liegt. XGBoost zeigt auch überlegene Stabilität mit geringerer Standardabweichung.

Algorithmus	R^2 (Mittel)	MAE (Mittel)	RMSE (Mittel)	Anzahl
XGBoost	0.380	0.239	0.308	64
LightGBM	0.237	0.278	0.347	64
Vorteil XGB	+0.143	-0.038	-0.039	—

Tab. 3: Algorithmus-Vergleich: Zufalls-Validierung (alle Komplexitätsstufen)

Die beste Modell-Konfiguration in der Zufalls-Validierung ist ein XGBoost-Modell mit Very Deep-Komplexität, ohne kategoriale Features, mit Feature-Aggregation und ohne Zielvariablen-Glättung. Dieses Modell erreicht ein R^2 von 0,657, RMSE von 0,233 und MAE von 0,176. Dies deutet darauf hin, dass XGBoost unter Bedingungen mit ausreichender Komplexität und geeigneter Feature-Konfiguration starke Vorhersagefähigkeit entwickelt. Bemerkenswerterweise ist die mittlere Komplexität nicht universell optimal. Medium und Very Deep erzielen ähnlich gute Durchschnittswerte (R^2 von 0.336 bzw. 0.328), während Shallow mit 0.245 deutlich schlechter abschneidet. Dies deutet darauf hin, dass eine Mindest-Modellkapazität erforderlich ist, dass aber zu tiefe Modelle auf Zufalls-Daten nicht zusätzlich helfen.

⁸⁰Vgl. Hodson 2022, S. 5481 f.

Konfiguration	R ² (Mittel)	MAE (Mittel)	RMSE (Mittel)	Anzahl
Shallow	0.245	0.220	0.343	32
Medium	0.336	0.183	0.322	32
Deep	0.325	0.191	0.324	32
Very Deep	0.328	0.186	0.323	32

Tab. 4: Zufalls-Validierung: Performance nach Hyperparameter-Komplexitätsstufe

Die Glättungsvarianten zeigen eine optimale Performance bei Fenstergrößen von 2–3, mit Fenstergröße 3 leicht vorne (R^2 0.324). Fenstergröße 4 verschlechtert die Performance (R^2 0.297). Feature-Aggregation liefert einen konsistenten, wenn auch moderaten Vorteil (+0.024 R^2). Überraschenderweise profitieren Zufalls-Validierungsergebnisse deutlich von der Abwesenheit kategorialer Features: Modelle ohne kategoriale Features erreichen R^2 0.466 gegenüber R^2 0.150 mit kategorialen Features eine Differenz von 0.316. Dies ist ein starker Indikator für Overfitting auf kategoriale Variablen.

Konfiguration	R ² (Mittel)	Varianz	RMSE (Mittel)	Modelle
Kategoriale Features:				
Ohne kategorische Features	0.466	0.195	0.289	64
Mit kategorialen Features	0.150	0.080	0.367	64
Feature-Aggregation:				
Ohne Aggregation	0.296	0.183	0.331	64
Mit Aggregation	0.320	0.210	0.325	64
Glättung (Fenstergrößen):				
Fenster 0 (keine)	0.309	0.195	0.328	32
Fenster 2	0.304	0.215	0.329	32
Fenster 3	0.324	0.186	0.325	32
Fenster 4	0.297	0.197	0.331	32

Tab. 5: Zufalls-Validierung: Effekte der Datensatzstruktur-Varianten

Auf dem Zufalls-Validierungsdatensatz demonstriert das beste Modell (XGBoost Very Deep, $R^2 = 0.657$) starke Vorhersagefähigkeit. Der Durchschnitt über alle Modelle liegt bei akzeptablen R^2 0.308. Diese Befunde suggerieren, dass das entwickelte Artefakt unter bekannten Datenverteilungen verlässliche Prognosen liefert.

5.2.2 Modell-Performance auf Event-Validierungsdatensätzen

Die Event-basierte Validierung wendet das trainierte Modell auf ein vollständig unbekanntes Renn-Event an und prüft damit die echte Generalisierungsfähigkeit auf neue Rennkontexte, Fahrzeugkonfigurationen und Streckeneigenschaften. Die Befunde in diesem Szenario sind fundamental kritisch. Die durchschnittliche R^2 beträgt -0.306 (± 0.256), eine deutlich negative Zahl.

Dies bedeutet, dass das durchschnittliche Modell schlechter abschneidet als eine triviale Baseline (z.B. Mittelwert-Vorhersage). Die Range erstreckt sich von -1.135 bis 0.093 , wobei 25 von 128 Modellen ein R^2 unter -0.5 aufweisen, ein Indikator extremer Fehlvorhersagen. Zusätzlich beträgt die RMSE durchschnittlich 0.325 (± 0.032), was zwar der Random-Validierung ähnelt, aber auf Grund der negativen R^2 -Werte nicht aussagekräftig ist. LightGBM zeigt eine überlegene Event-Generalisierbarkeit mit $R^2 -0.268$ (± 0.277) gegenüber XGBoost mit -0.343 (± 0.229). Der beste LightGBM-Event-Score ($R^2 0.093$) ist deutlich höher als der beste XGBoost-Event-Score ($R^2 0.029$).

Algorithmus	R^2 (Mittel)	R^2 (Best)	RMSE (Mittel)	Modelle
LightGBM	-0.268	0.093	0.320	64
XGBoost	-0.343	0.029	0.330	64
Vorteil LGB	+0.075	+0.064	-0.010	–

Tab. 6: Algorithmus-Vergleich: Event-Validierung (alle Komplexitätsstufen)

Die beste Modell-Konfiguration in der Event-Validierung ist ein LightGBM-Modell mit Very-Deep-Komplexität, mit kategorialen Features, ohne Feature-Aggregation und ohne Zielvariablen-Glättung. Dieses Modell erreicht $R^2 0.093$, RMSE 0.272 und MAE 0.212. Auch diese beste Konfiguration bleibt problematisch niedrig.

Tiefere Modelle zeigen relativ bessere Event-Generalisierung: Very Deep ($R^2 -0.232$) übertrifft Shallow ($R^2 -0.405$) um 0.173 Punkte. Dies deutet darauf hin, dass höhere Modellkomplexität das Generalisierungsproblem nicht verschärft. Allerdings sind alle Komplexitätsstufen im absoluten Sinne unzureichend. Der beobachtete Trend sollte daher nicht als Beleg für robustere Modelle interpretiert werden, sondern lediglich als Hinweis, dass Overfitting durch Komplexität in diesem Fall nicht der limitierende Faktor ist.

Komplexitätsstufe	R^2 (Mittel)	Varianz	RMSE (Mittel)	Modelle
Shallow	-0.405	0.317	0.337	32
Medium	-0.318	0.233	0.327	32
Deep	-0.267	0.235	0.321	32
Very Deep	-0.232	0.204	0.317	32

Tab. 7: Event-Validierung: Performance nach Hyperparameter-Komplexitätsstufe

Bei der Event-Generalisierung zeigt Glättung (Fenster 3: $R^2 -0.281$) einen marginalen Vorteil gegenüber keiner Glättung ($R^2 -0.330$). Kategoriale Features sind ambivalent. Sie verbessern Event-Generalisierung erheblich (mit: $R^2 -0.140$ vs. ohne: $R^2 -0.471$, Delta- $R^2 +0.331$), schaden aber massiv in der Random-Validierung (mit: $R^2 0.150$ vs. ohne: $R^2 0.466$, Delta- $R^2 -0.316$).

Konfiguration	R ² (Mittel)	Varianz	RMSE (Mittel)	Modelle
Kategoriale Features:				
Mit kategorialen Features	-0.140	0.207	0.304	64
Ohne kategorische Features	-0.471	0.184	0.346	64
Feature-Aggregation:				
Mit Aggregation	-0.300	0.248	0.325	64
Ohne Aggregation	-0.311	0.266	0.326	64
Glättung (Fenstergrößen):				
Fenster 0 (keine)	-0.330	0.316	0.328	32
Fenster 2	-0.296	0.259	0.324	32
Fenster 3	-0.281	0.219	0.323	32
Fenster 4	-0.315	0.229	0.327	32

Tab. 8: Event-Validierung: Effekte der Datensatzstruktur-Varianten

Die Event-Validierung offenbart ein fundamentales Generalisierungsproblem. Mit durchschnittlich negativer R² sind die Modelle in diesem Szenario nicht praktisch einsetzbar. Das beste Modell mit R² 0.093 ist gerade noch marginale besser als eine Baseline.

5.2.3 Interpretation des Gesamtergebnisses

Die massive Diskrepanz zwischen Zufalls- (R²-Mittel 0.308) und Event-Validierung (R²-Mittel -0.306) ist nicht auf typisches Overfitting zurückzuführen, sondern offenbart ein fundamentales Problem der Domänen-Generalisierung. Im Folgenden werden die wahrscheinlichen Ursachen und Implikationen dieser Diskrepanz erörtert.

Ein zentrales Problem besteht darin, dass die Telemetriedaten ausschließlich Fahrzeugzustände und Sensorwerte erfassen, jedoch die entscheidenden Kontextfaktoren, die das Understeer maßgeblich beeinflussen, nicht berücksichtigen. So sind beispielsweise individuelle Fahrereffekte wie Lenk-Aggression, Bremspunkt-Variabilität oder die Wahl der Fahrlinie in den Rohdaten mit physikalischen Fahrzeug-Eigenschaften vermischt und lassen sich nicht voneinander trennen. Das Modell erlernt dadurch eine Kombination aus Fahrzeugverhalten und Fahrercharakteristik, die bei neuen Fahrern nicht übertragbar ist. Hinzu kommt, dass das Fahrzeug-Setup, etwa Chassis-Steifigkeit, Aero-Balance oder Federung, sich zwischen den Events und sogar innerhalb eines Events verändert. Diese Parameter sind in den Telemetriedaten nicht explizit enthalten und können allenfalls indirekt über die Reaktion des Fahrzeugs auf die Fahrbahn abgeleitet werden, was jedoch eine unzureichende und wenig robuste Methode darstellt. Darüber hinaus spielen Umgebungsfaktoren wie Streckentemperatur, Luftdichte, Feuchtigkeit und Windverhältnisse eine fundamentale Rolle für Aerodynamik und Reifenverhalten. Da diese Einflussgrößen im Datensatz nicht enthalten sind, können sie auch nicht rekonstruiert werden.

Diese fehlenden Faktoren erklären, warum das Modell eine hohe Performance auf dem Zufallsdatensatz erreicht (es memorisiert Training-Event-Muster) aber bei Event-Transfer kollabiert (neue Kombinationen aus Fahrer, Setup, Reifen, Umwelt sind unbekannt).

Das zentrale Problem ist ein Covariate-Shift: Die Verteilung der Eingabedaten unterscheidet sich zwischen Training und Event-Test, während das Modell unter der Annahme konstanter Kontextfaktoren trainiert wurde. Bei neuen Fahrern, Setups oder Umwelteinflüssen versagt diese Annahme, und die Generalisierung bricht ein. Der Event-Validierungsdatensatz dient somit als Stress-Test für echte Domain Generalization. Für zukünftige ML-Projekte gilt: Die Datenqualität ist entscheidender als die Wahl des Algorithmus, und die Verwendung kategorialer Features sollte mit Blick auf die Ziel-Domäne erfolgen. Robustere Generalisierung erfordert gezieltes Feature-Engineering und Transfer-Learning-Ansätze, da Modelle ohne explizite Berücksichtigung neuer Kontexte nicht zuverlässig auf unbekannte Strecken übertragbar sind.

6 Fazit, Erkenntnisse und Forschungsausblick

Mit Kapitel 5 wurde die technische Evaluierung des Vorhersagemodells abgeschlossen. Das vorliegende Kapitel schließt den Design Cycle durch Reflexion, Synthese und Kommunikation ab. Dabei werden die empirischen Ergebnisse der Evaluierung explizit gegen die in Kapitel 3 formulierten Anforderungen und Forschungsfragen abgewogen. Zentral ist die kritische Analyse der identifizierten Leistungsgrenzen. Abschließend werden generalisierbare Design Principles und Erkenntnisse für zukünftige ML-Projekte im Motorsport-Kontext abgeleitet, wodurch diese Arbeit über das konkrete Artefakt hinaus einen Beitrag zur Wissensbasis leistet.

6.1 Erfüllung der Anforderungen und Beantwortung der Forschungsfragen

Die vorliegende Arbeit verfolgte das Ziel, ein ML-Modell zur automatisierten Vorhersage von Understeer-Verhalten in Motorsport-Telemetriedaten zu entwickeln. Zur Bewertung des Erfolgs werden sowohl die technischen Anforderungen als auch die formulierten Forschungsfragen gegen die erhaltenen Ergebnisse abgewogen.

Anforderung 1: Automatisierte Understeer-Vorhersage

Die Anforderung, ein ML-Modell zur Vorhersage von Understeer-Werten auf Basis von Telemetriedaten zu entwickeln, ist partiell erfüllt. Das beste Modell auf dem Zufalls-Validierungsdatensatz (XGBoost, Very Deep, $R^2 = 0.657$) demonstriert, dass Understeer-Vorhersage unter kontrollierten Bedingungen möglich ist. Die durchschnittliche Performance auf dem Zufallsdatensatz über alle 128 Modelle beträgt $R^2 = 0.308$, was darauf hindeutet, dass die Modelle etwa ein Drittel der Varianz in der Zielvariablen erfassen. Allerdings ist diese Performance auf die spezifische Datenverteilung des Trainingsdatensatzes beschränkt. Bei der Event-Validierung, dem realistischeren Szenario mit vollständig unbekannten Rennkontexten, kollabiert die Performance dramatisch. Das beste Event-Modell (LightGBM, Very Deep, $R^2 = 0.093$) erreicht nur marginal bessere Ergebnisse als eine Baseline-Vorhersage, und der Durchschnitt über alle Modelle beträgt $R^2 = -0.306$, was bedeutet, dass die Modelle schlechter abschneiden als triviale Vergleichsmodelle. Diese Diskrepanz offenbart, dass das Ziel einer produktionsreifen, generalisierbaren Vorhersage nicht erreicht wurde.

Anforderung 2: Hohe Vorhersagegenauigkeit

Die angestrebte Vorhersagegenauigkeit von $R^2 > 0,7$ wurde nicht erreicht. Das beste Zufalls-Modell erreicht $R^2 = 0,657$, knapp unterhalb der Zielvorgabe, scheitert aber bei Event-Generalisierung ($R^2 = 0,093$). Die Ursachenanalyse in Kapitel 5.3 identifiziert als Primärproblem nicht algorithmische Limitationen, sondern fehlende Kontextfaktoren: Fahrercharakteristiken, Setup-Parameter, Reifen-Degradation und Umgebungsdaten sind in den verfügbaren Telemetriedaten

nicht erfasst und können nicht aus Sensorwerten rekonstruiert werden. Diese fehlenden Variablen determinieren das Understeer-Verhalten fundamental und liefern eine mögliche Erklärung für die schwache Event-Generalisierung.

6.2 Beantwortung der Forschungsfragen

Forschungsfrage 1: Können Gradient Boosting Decision Trees Understeer-Verhalten in Motorsport-Telemetriedaten vorhersagen?

Die Antwort lautet: Teilweise ja, aber nur unter stark einschränkenden Bedingungen. GBDT-Modelle funktionieren auf trainierten Datensätzen gut (durchschnittliche Zufalls-Validierung: $R^2 = 0,308$) und zeigen damit, dass Understeer grundsätzlich aus Telemetriedaten extrahierbar ist. Allerdings generalisieren diese Modelle nicht auf unbekannte Rennkontexte (durchschnittliche Event-Validierung: $R^2 = -0,306$). Das Problem liegt nicht in der Algorithmuswahl, sondern in der fehlenden Datengrundlage. GBDT memorisieren Muster aus trainierten Events (Track-spezifische Telemetrie-Signaturen), können diese aber nicht auf neue Tracks, neue Fahrer*innen oder neue Setup-Konfigurationen übertragen.

Forschungsfrage 2: Welcher Algorithmus (XGBoost vs. LightGBM) generalisiert besser?

Weder XGBoost noch LightGBM zeigt konsistente Überlegenheit. Bei Event-Generalisierung ist LightGBM leicht besser (durchschnittliche $R^2 = -0,268$ vs. XGBoost $-0,343$), mit dem besten Event-Modell bei $R^2 = 0,093$ (LightGBM) vs. $R^2 = 0,029$ (XGBoost). Bei Zufalls-Validierung dominiert XGBoost deutlich (durchschnittliche $R^2 = 0,380$ vs. LightGBM $0,237$), mit dem besten Modell bei $R^2 = 0,657$ (XGBoost) vs. $R^2 = 0,458$ (LightGBM). Diese gegensätzliche Leistung unterstreicht, dass algorithmische Wahl sekundär ist. Beide Algorithmen leiden unter denselben fundamentalen Limitationen: fehlende Kontextfaktoren.

Forschungsfrage 3: Wie wirken sich Datenvorbereitung und Hyperparameter-Tuning auf die Performance aus?

Der größte Effekt stammt nicht aus Hyperparameter-Tuning, sondern aus der Feature-Konfiguration, insbesondere der Verwendung kategorialer Features. In der Event-Validierung helfen kategoriale Features (primär Track-Information) um $\Delta R^2 = +0,331$ (mit Kategorisch: $R^2 = -0,140$ vs. ohne: $R^2 = -0,471$). In der Zufalls-Validierung schaden sie um $\Delta R^2 = -0,316$ (mit Kategorisch: $R^2 = 0,150$ vs. ohne: $R^2 = 0,466$). Glättungsvarianten zeigen moderate Effekte (optimal: Fenster 3, ΔR^2 ca. $0,03$ – $0,05$), und Feature-Aggregation hat minimalen Effekt ($\Delta R^2 < 0,03$). Hyperparameter-Komplexitätsstufen zeigen, dass tiefere Modelle bei Event-Generalisierung helfen (Very Deep besser als Shallow um $\Delta R^2 = +0,173$), was gegen klassisches Overfitting-Verständnis spricht und eher auf Domain-Shift-Probleme hindeutet.

6.3 Design Knowledge und kritische Selbsteinschätzung

Bedauernswerterweise konnte das Ziel, ein ML-Modell zur Vorhersage der Fahrzeugbalance zu entwickeln, nicht erreicht werden. Trotz intensiver Bemühungen in der Datensammlung (17.735 Runden aus 40 Events), Datenvorbereitung (16 Strukturvarianten) und Modellierung (128 trainierte Modelle) blieb die angestrebte Prognosegenauigkeit aus, sodass diese Arbeit kein in der Praxis nutzbares Artefakt hervorgebracht hat. Im Normalfall würden nun mehrere Iterationen der Cycles durchlaufen werden, was im Rahmen dieser Arbeit aufgrund von Zeit- und Ressourcenbeschränkungen nicht möglich war.⁸¹

Aus Sicht der Design Science Research Methodik ist die Evaluate-Phase vollständig dokumentiert: Der Rigor Cycle wurde mit systematischen Evaluationen, etablierten Metriken und 256 Evaluationsergebnissen erfüllt.⁸² Der Relevance Cycle wurde teilweise erfüllt und die zugrunde liegenden Probleme aufgezeigt, die Lösung erfordert aber Daten, die außerhalb des Projektumfangs liegen.

Aus den Erkenntnissen des Entwicklungsprozesses ergeben sich folgende Design Principles für zukünftige Arbeiten: Die algorithmische Wahl (XGBoost vs. LightGBM) ist für die Vorhersagegenauigkeit nachrangig; entscheidend ist die Datenqualität und die Berücksichtigung relevanter Kontextfaktoren. Kategoriale Features wie Track-Informationen verbessern die Modellleistung innerhalb bekannter Datenbereiche, verschlechtern jedoch die Generalisierung auf neue Events, da sie lediglich Trainingsmuster memorisieren. Die Analyse zeigt, dass Domain Shift, also Unterschiede in der Verteilung der Eingabedaten zwischen Trainings- und Testevents, größere Auswirkungen hat als klassisches Overfitting; tiefere Modelle können unter diesen Bedingungen sogar besser generalisieren. Event-basierte Validierung ist daher essenziell, da sie die tatsächliche Generalisierungsfähigkeit offenbart und Random-Validierung zu optimistischen Einschätzungen führt. Insgesamt bleibt die fehlende Erfassung von Kontextfaktoren wie Fahrercharakteristiken, Setup-Parametern, Reifenstatus und Umgebungsbedingungen die zentrale Limitation, die mit reiner Telemetrie nicht überwunden werden kann.

Was dennoch bleibt sind die Erkenntnisse aus dem Entwicklungsprozess, die wertvolle Einblicke in die Herausforderungen und Limitationen bei der Anwendung von ML im Motorsport-Kontext bieten und einen Grundstein für zukünftige Arbeiten legen.

⁸¹Vgl. Hevner et al. 2004, S. 83

⁸²Vgl. Venable, Pries-Heje, Baskerville 2016, S. 77 ff.

Anhang

Anhangverzeichnis

Anhang 1	Transkripte der Experteninterviews	34
Anhang 1/1	Erstes Meeting mit Performance-Ingenieur (29.08.2025)	34
Anhang 1/2	Zweites Meeting mit Performance-Ingenieur (12.09.2025)	38
Anhang 1/3	Methodische Anmerkungen zu den Interviews	40
Anhang 2	Modell-Ergebnisse	40
Anhang 2/1	Ergebnisse der Event-Validierung	40
Anhang 2/2	Ergebnisse der Zufalls-Validierung	43

Anhang 1: Transkripte der Experteninterviews

Anhang 1/1: Erstes Meeting mit Performance-Ingenieur (29.08.2025)

Experte: Teamleiter Performance Engineering (LMDh-Programm), Porsche Motorsport **Datum:** 29.08.2025

1 **Interviewer: Meeting-Eröffnung** Vielen Dank für deine Zeit. Könntest du dich bitte kurz
2 vorstellen?

3 **Ingenieur: Vorstellung und Aufgabengebiet** Gerne. Ich bin schon länger bei Porsche und
4 leite das LMDh Performance Team. Ich war bereits in der LMP und Formel E tätig. Unsere
5 Aufgaben umfassen Performance, besonders in der Entwicklung, die Simulations- und Kenn-
6 wertvorgabe für andere Abteilungen (z.B. wie viel Drag und Abtrieb das Auto benötigt), die
7 Reifenentwicklung mit Michelin, die Rundenzeitberechnung inklusive Modellierung, sowie die
8 Datenanalyse im operativen Betrieb. Auch performancerelevante Software im Auto kommt von
9 uns, etwa die Funktionskontrolle.

10 **Interviewer: Definition und Aufgaben des Performance Engineers** Du hast die Rolle
11 bereits kurz angeschnitten. Könntest du die Jobrolle des Performance Engineers bitte noch einmal
12 grundlegend erklären und einordnen, wie die typische Datenanalyse an einem Rennwochenende
13 abläuft?

14 **Ingenieur: Rolle und Setup-Optimierung** Performance-Ingenieure sind primär für die Per-
15 formance des Autos verantwortlich. Das heißt, das Auto muss möglichst optimal auf der Strecke
16 eingesetzt werden, logischerweise bezüglich der Rundenzeit. Ein zweiter wichtiger Punkt ist die
17 Betriebssicherheit des Autos. Wir überwachen kritische Parameter wie Bremstemperatur oder
18 Fahrhöhen. Bei Abweichungen melden wir Probleme, damit der Renningenieur das Auto zur
19 Reparatur reinholen kann. Unsere Hauptaufgabe ist die Setup-Arbeit am Auto, die wir wäh-
20 rend des Rennwochenendes bis zum Rennen optimieren. Dies geschieht in Abstimmung mit dem
21 Renningenieur und dem Fahrer.

22 **Ingenieur: Daten und Setup-Entscheidung** Nach jeder Setup-Änderung ist das Feedback
23 des Fahrers essenziell. Dieses fließt zusammen mit den Daten (Telemetrie oder Kabeldaten) in
24 die Entscheidungsfindung ein. Wir analysieren die Daten, um die Balance des Autos (Unter- oder
25 Übersteuern) zu prüfen und die Fahrhöhen zu optimieren. Das ist die Kernaufgabe: Das Auto
26 zusammen mit dem Renningenieur und dem Fahrer zu optimieren. Wir tragen die Verantwortung
27 für das Setup.

28 **Interviewer: Prozess am Rennwochenende** Wie sieht dieses Zusammenspiel an einem Renn-
29 wochenende genau aus? Es werden Daten gesammelt, die Autos sind auf der Strecke. Gibt es
30 mehrere Performance Engineers, die spezifische Datenbereiche überwachen?

31 **Ingenieur: Simulation und Validierung** Der Performance Engineer nutzt Simulationstools.
32 Wenn ich beispielsweise die Feder ändere, simuliert das Tool, wie sich das auf Fahrhöhe oder

33 Abtrieb auswirkt. Diese Theorie wird dann mit den Streckendaten abgeglichen. Der Performance
34 Engineer bereitet sich intensiv vor und legt vorab eine Auswahl an Setups fest (einen Blumen-
35 strauß an Optionen), die auf Erfahrungswerten und Fahrsimulatordaten basieren. An der Strecke
36 werden diese Optionen gefahren, um die Theorie zu validieren und das beste Setup für das Qua-
37 lifying und das Rennen auszuwählen.

38 **Ingenieur: Setup-Umsetzung** Der Performance Engineer definiert das Setup. Über ein Tablet
39 erhalten die Mechaniker die Anweisung für die Setup-Änderungen (z.B. Federwechsel, Fahrhöhe
40 anpassen). Der Chefmechaniker koordiniert die Umsetzung. Sobald die Änderungen umgesetzt
41 sind, geht das Auto auf die Strecke, liefert neue Daten, und der Prozess der Optimierung läuft
42 iterativ weiter.

43 **Interviewer: Überleitung zum Machine Learning (ML) Projekt** Vielen Dank, das war
44 ein sehr hilfreicher Überblick. Ich möchte jetzt kurz unser Projekt vorstellen. Wir arbeiten an
45 einem Proof of Concept für Machine Learning, bei dem wir ein Modell auf Telemetriedaten
46 trainieren wollen.

47 **Interviewer: Erläuterung ML-Typen (Klassifikation)** Ganz grundlegend: Bei Klassifikati-
48 onsmodellen werden viele Telemetrie-Inputs verarbeitet, um eine diskrete Kategorie auszugeben.
49 Das könnte beispielsweise die Reifenmischung (Soft, Medium) oder das Fahrverhalten (aggressiv,
50 optimal) sein.

51 **Interviewer: Erläuterung ML-Typen (Regression/Vorhersage)** Der zweite Typ sind Vorhersage-
52 oder Regressionsmodelle. Diese werden trainiert, um einen Wert vorherzusagen, wie zum Beispiel
53 die Rundenzeit. Das Modell würde auf Basis der aktuellen Telemetriedaten in den ersten Sektoren
54 die prognostizierte Endrundenzeit voraussagen.

55 **Interviewer: Erläuterung Trainingsdaten und Labeling** Für das Training benötigen wir
56 den Input (Telemetriedaten) und den wahren Output (das Label). Das Label muss entweder be-
57 rechnet werden können oder in den Daten bereits vorhanden sein, da wir den manuellen Aufwand
58 gering halten wollen.

59 **Ingenieur: Rundenzeit-Vorhersage und Alternativen** Die Predicted Laptime haben wir
60 bereits im Auto. Das ist ein simpler, aber gut funktionierender, nicht-ML-basierter Ansatz. Des-
61 halb sollten wir uns auf etwas konzentrieren, das es noch nicht gibt.

62 **Ingenieur: Herausforderung und Ideen (Reifen/Setup)** Wir generieren sehr viele Daten,
63 auch Kennzahlen (KPIs). Die Schwierigkeit ist, die Zusammenhänge in kurzer Zeit zu verstehen.
64 Zum Beispiel: Wie beeinflusst das aggressive Aufwärmen des Reifens in den ersten Runden den
65 Grip in Runde 20? Oder die schnelle Entscheidung, welcher optimale Compound bei 40 Grad
66 Streckentemperatur zu wählen ist.

67 **Ingenieur: Fahrer-Feedback und Reifenüberhitzung** Ein sehr interessanter Ansatz wäre die
68 Guidance für den Fahrer. Wenn der Fahrer durch zu viel Schlupf den Reifen überfährt und dieser
69 dann abbaut, könnte das Modell ihm mitteilen: Fahre konservativer, wir sehen in den Daten,

70 du überfährst den Reifen gerade. Hierzu müssten wir den Schlupf oder die Reifentemperatur
71 überwachen.

72 **Interviewer: Potential des ML-Modells** Die Idee, aus verschiedenen Telemetrie-Channels
73 den Output überfahren / nicht überfahren zu generieren, ist sehr vielversprechend. Hier liegt ein
74 großer Benefit, da dies momentan auf jahrelanger Erfahrung und Bauchgefühl basiert und nicht
75 einfach in Code abzubilden ist.

76 **Ingenieur: Labelling als Problem und alternative Kennwerte** Das Hauptproblem wäre
77 das Training und die Label-Generierung. Wir müssten definieren: Hier, zu diesem Zeitpunkt
78 wurde der Reifen überfahren. Wenn dieses Label nicht einfach aus den Telemetriedaten ableitbar
79 ist, müsste jemand manuell die Daten durchsehen und markieren, was für euch nicht praktikabel
80 ist.

81 **Ingenieur: Kennwert Snaps** Wir haben alternative Kennwerte. Zum Beispiel die Anzahl der
82 Snaps pro Runde: wie häufig das Heck beim Beschleunigen ausbricht. Wenn der Reifen abgebaut
83 ist, passiert dies häufiger.

84 **Ingenieur: Long-Run-Daten und Lebensdauer-Prognose** Ein weiteres Kriterium ist die
85 Rundenzeit über einen Long Run. Man sieht, wie die Rundenzeit mit der Anzahl der Runden
86 schlechter wird. Hier könnte man visualisieren, wann der Reifen tatsächlich seine Leistung ver-
87 liert.

88 **Interviewer: Präzisierung der Prognose-Idee** Man könnte auf Basis des aktuellen Fahrver-
89 haltens eine Lebensdauer prognostizieren. Beispiel: Basierend auf den letzten zwei Sektoren hält
90 der Reifen noch drei Runden. Führt der Fahrer konservativer, steigt der Wert auf fünf.

91 **Ingenieur: Einschränkung der Datenbasis** Gibt man dem Modell nur die Rundenzeit, weiß
92 es nicht, *warum* die Zeit schlechter wird (war es das Setup, der Fahrer, der Fahrstil?). Das
93 Modell benötigt auch Input über den Fahrer und die genauen Setup-Einstellungen.

94 **Ingenieur: Empfehlung für Proof of Concept (POC)** Für den POC sollten wir Daten von
95 Le Mans oder einem Dauerlauf verwenden, bei denen das Setup konstant war. Dann sind nur
96 noch Fahrer- oder Fahrstilunterschiede relevant.

97 **Interviewer: Fehlerhafte Temperatursensoren** Wir sehen in den Daten an manchen Stellen
98 Ausreißer in der Reifentemperatur. Ist das nur auf Sensorfehler zurückzuführen, oder gibt es
99 Grenzwerte, ab denen die Temperatur kritisch wird?

100 **Ingenieur: Kritischer Grenzwert und Sensorfehler** Manche dieser Ausreißer können auf
101 Sensorprobleme zurückzuführen sein. Die Infrarot-Sensoren zur Messung der Oberflächentempe-
102 ratur fallen öfter aus, zum Beispiel, wenn Gummiabrieb an den Sensor gelangt und ihn beschädigt.
103 Kritische Grenzwerte sind aber auch ein Thema: Alles, was Werte um die 300 Grad erreicht, deu-
104 tet darauf hin, dass der Reifen zu schmelzen beginnt. Solche fehlerhaften oder extrem kritischen
105 Werte lassen sich glücklicherweise mit einem einfachen Filter gut bereinigen.

106 **Interviewer: Abschluss und nächster Termin** Die Idee mit dem Dauerlauf ist ein sehr guter
107 Startpunkt für einen Proof of Concept. Ich werde mich jetzt einarbeiten und in zwei Wochen
108 einen neuen Termin vorschlagen.

109 **Ingenieur: Wunsch für nächstes Meeting** Es wäre gut, wenn du für das nächste Meeting
110 visualisierst, wie du dir den Prozess vorstellst: Hier kommen Daten rein, das passiert, das kommt
111 als Output raus.

112 **Interviewer: Abschluss** Vielen Dank für deine Zeit.

Anhang 1/2: Zweites Meeting mit Performance-Ingenieur (12.09.2025)

Experte: Teamleiter Performance Engineering (LMDh-Programm), Porsche Motorsport **Datum:** 12.09.2025

1 **Interviewer: Problemstellung Reifendegradation und neuer Ansatz** Das Thema Reifen-
2 degradation ist sehr interessant, aber das Labeln ist eine zu große Hürde. Es ist zu wenig Zeit,
3 um euer langjähriges Bauchgefühl in manuell definierte Schwellwerte zu überführen.

4 **Interviewer: Neue Idee: Fahrerfeedback / Explainability AI** Die neue Idee ist, ein Modell
5 zu trainieren, um Fahrerfeedback zu generieren. Wir trainieren das Modell auf die verschiedenen
6 Fahrer und nutzen dann Explainability AI. Das würde die KI-Black-Box aufbrechen und zeigen,
7 wie die KI zu ihrer Entscheidung kommt. Der Mehrwert: Die KI könnte die Unterschiede zwischen
8 den Fahrern aufzeigen und erklären, warum Fahrer 1 in Sektor X schneller war. Der Vorteil für
9 mich ist, dass das Label (welcher Fahrer fährt gerade) einfach aus den Daten zu ziehen ist.

10 **Ingenieur: Vorschlag: Fokus auf Fahrzeugbalance (Car Balance)** Was uns aktuell sehr
11 beschäftigt, ist die Fahrzeugbalance. Ist das Auto eher neutral oder untersteuernd? Die Balance
12 hängt von vielen Parametern ab, deren Zusammenhänge für uns Menschen schwierig zu verstehen
13 sind.

14 **Ingenieur: Modellierung der Balance** Man könnte sich das als eine Gleichung vorstellen:
15 Das Y (Fahrzeug Balance) hängt von vielen Eingangswerten X ab (Streckentemperatur, Reifen-
16 temperatur, -druck, Fahrer, etc.). Dazwischen liegt eine Funktion, die wir nicht genau kennen.

17 **Interviewer: Tool-Nutzung** Welche Tools verwendet ihr live an der Strecke? PowerBi Dash-
18 board oder die genauen Telemetriedaten in Wintax?

19 **Ingenieur: Balance-Definition und Metriken** Beides. Wintax ist der reine Telemetriedaten-
20 strom. Zusätzlich haben wir Auswertungen und Kennwerte. Wir haben Cluster für den Kurven-
21 eingang, die Kurvenmitte und den Kurvenausgang, und dazu die Balance als Mittelwert über
22 alle Kurven.

23 **Interviewer: Definition Balance** Was genau ist diese Balance?

24 **Ingenieur: Erklärung der Car Balance** Die Balance beschreibt, ob das Auto viel Unter-
25 steuern hat. Mathematisch hängt es vom Lenkwinkel (Input vom Fahrer) und der Gierrate (wie
26 schnell sich das Auto dreht) ab. Ist die Reaktion der Gierrate auf den Lenkwinkel direkt, ist das
27 Auto neutral. Muss der Fahrer extrem viel lenken ohne Reaktion, ist es untersteuernd. Reagiert
28 das Auto zu schnell, ist es übersteuernd.

29 **Ingenieur: Der Kern der Fragestellung** Interessant ist: Das ist unser Y (die Balance), aber
30 wir verstehen nicht, warum dieser Zustand eintritt. Liegt es daran, dass der Fahrer etwas verstellt
31 hat, sich die Streckentemperatur geändert hat oder der Reifen mehr Kilometer Laufleistung hat?
32 Das ist die Frage, die uns am Ende interessiert.

33 **Ingenieur: Beispiel Streckentemperatur** Wenn wir den Einfluss der Streckentemperatur auf
34 die Balance wüssten, wäre das hilfreich. Sagt der Fahrer im FP2 (20 Grad heißer) die Balance
35 sei schlecht, könnten wir sagen: Das liegt an der Strecke. Im Rennen wird es kälter, das passt
36 dann alles.

37 **Interviewer: Bewertung des Car Balance Themas** Verstehe. Hier hätten wir das Labeling
38 (die Balance) also schon. Das ist ein komplett anderes, aber sehr vielversprechendes Thema.

39 **Ingenieur: Update zum Degradations-Kennwert** Der Verschleiß-Kennwert ist noch nicht
40 verfügbar. Die Kollegen bekommen die Berechnung der Degradation (die wie die Balance berech-
41 net werden soll) nicht mehr bis Ende November in die Datenplattform.

42 **Ingenieur: Modellierung des Degradations-Kennwerts** Dahinter steckt ein Reifenmodell.
43 Wir modellieren einen neuen Reifen und optimieren dann die Modellparameter (z.B. den Grip-
44 Parameter), damit sie zu den Messdaten passen. Diese Optimierung wird aktuell noch händisch
45 in Matlab durchgeführt, bevor sie in die Datenplattform integriert wird.

46 **Interviewer: Rückkehr zum Car Balance POC** Die Car Balance ist ein guter Ansatz für
47 den POC. Das wäre die Zielvariable, zum Beispiel die Highspeed-Balance in der Kurvenmitte.

48 **Ingenieur: Empfehlung für POC-Umfang** Ich würde vorschlagen, es pro Auto zu machen,
49 da die Setups unterschiedlich sind. Man könnte auch die Daten aller Autos zusammenwerfen, um
50 generelle Regeln zu finden, aber man sollte mit einem Auto starten.

51 **Ingenieur: Datenverfügbarkeit und Mileage** Wir haben fast alle benötigten Inputs (X-
52 Werte) im Dashboard, außer die Mileage (Laufleistung des Reifens), die aber wichtig ist und als
53 Anzahl der gefahrenen Runden in den Daten existiert.

54 **Ingenieur: Allgemeiner Problemkern** Es gibt verschiedene Themen, bei denen wir eine Me-
55 trik (Y) und die Eingangsvariablen (X) kennen, aber nicht wissen, wie diese zusammenhängen.
56 Das gilt für die Degradation und die Balance. Unser Ansatz wäre: Wir nutzen die enormen
57 Datenmengen, um die Zusammenhänge zu verstehen. Das wäre wirklich sehr hilfreich.

58 **Interviewer: Abschluss** Vielen Dank für das Gespräch, ich glaube, das hat sehr geholfen.

Anhang 1/3: Methodische Anmerkungen zu den Interviews

Die Interviews wurden als unstrukturierte Experteninterviews geführt und digital aufgezeichnet. Die vorliegenden Transkripte sind Rohtranskripte, die zur besseren Lesbarkeit geglättet wurden, jedoch den originalen Gesprächsinhalt und -verlauf authentisch wiedergeben. Die beibehaltenen Zeilennummern dienen der präzisen Zitierfähigkeit.

Die Gespräche dienten der:

- Anforderungsanalyse für das Machine Learning Projekt
- Identifikation relevanter Telemetriedaten und Kenngrößen
- Bewertung verschiedener Ansätze (Fokusverlagerung von Reifendegradation zu Car Balance)
- Klärung technischer Umsetzbarkeit und Datenverfügbarkeit

Anhang 2: Modell-Ergebnisse

Anhang 2/1: Ergebnisse der Event-Validierung

Modelltyp	Parametertiefe	Kategorisch	Aggregate	Smoothed	MAE	RMSE	R2
xgb	shallow	True	True	0	0.272	0.344	-0.443
lgb	shallow	True	True	0	0.25	0.318	-0.239
xgb	deep	False	True	4	0.259	0.33	-0.332
lgb	deep	False	True	4	0.316	0.394	-0.895
xgb	deep	True	False	2	0.242	0.308	-0.162
lgb	deep	True	False	2	0.222	0.284	0.012
xgb	medium	False	True	3	0.277	0.344	-0.443
lgb	medium	False	True	3	0.267	0.335	-0.372
xgb	shallow	False	False	2	0.307	0.38	-0.761
lgb	shallow	False	False	2	0.256	0.33	-0.327
xgb	very-deep	False	True	0	0.267	0.335	-0.372
lgb	very-deep	False	True	0	0.296	0.365	-0.625
xgb	medium	True	False	2	0.259	0.325	-0.291
lgb	medium	True	False	2	0.216	0.28	0.04
xgb	deep	True	True	3	0.23	0.297	-0.074
lgb	deep	True	True	3	0.237	0.303	-0.125
xgb	deep	True	True	2	0.226	0.292	-0.042
lgb	deep	True	True	2	0.235	0.301	-0.108
xgb	medium	False	False	3	0.266	0.336	-0.379
lgb	medium	False	False	3	0.309	0.384	-0.804

xgb,shallow,False,True,4,0.298,0.368,-0.656
 lgb,shallow,False,True,4,0.247,0.314,-0.206
 xgb,shallow,False,False,0,0.325,0.393,-0.884
 lgb,shallow,False,False,0,0.325,0.394,-0.899
 xgb,shallow,True,True,4,0.25,0.313,-0.196
 lgb,shallow,True,True,4,0.231,0.3,-0.1
 xgb,very-deep,False,False,3,0.259,0.328,-0.315
 lgb,very-deep,False,False,3,0.258,0.329,-0.322
 xgb,deep,True,False,3,0.24,0.307,-0.155
 lgb,deep,True,False,3,0.223,0.288,-0.013
 xgb,very-deep,True,False,3,0.239,0.306,-0.142
 lgb,very-deep,True,False,3,0.21,0.274,0.081
 xgb,shallow,False,False,3,0.29,0.362,-0.597
 lgb,shallow,False,False,3,0.267,0.342,-0.433
 xgb,shallow,True,False,2,0.267,0.345,-0.456
 lgb,shallow,True,False,2,0.212,0.276,0.067
 xgb,medium,True,False,4,0.287,0.36,-0.584
 lgb,medium,True,False,4,0.219,0.281,0.038
 xgb,very-deep,True,False,4,0.246,0.314,-0.204
 lgb,very-deep,True,False,4,0.22,0.283,0.02
 xgb,deep,False,True,2,0.279,0.346,-0.467
 lgb,deep,False,True,2,0.296,0.37,-0.672
 xgb,shallow,True,False,0,0.34,0.418,-1.135
 lgb,shallow,True,False,0,0.211,0.28,0.045
 xgb,deep,True,False,4,0.262,0.334,-0.366
 lgb,deep,True,False,4,0.223,0.288,-0.01
 xgb,very-deep,False,False,4,0.253,0.324,-0.282
 lgb,very-deep,False,False,4,0.282,0.354,-0.529
 xgb,deep,False,True,0,0.263,0.33,-0.334
 lgb,deep,False,True,0,0.299,0.366,-0.638
 xgb,medium,False,True,0,0.273,0.341,-0.425
 lgb,medium,False,True,0,0.322,0.394,-0.895
 xgb,deep,False,True,3,0.266,0.335,-0.373
 lgb,deep,False,True,3,0.262,0.33,-0.329
 xgb,shallow,False,True,0,0.285,0.356,-0.551
 lgb,shallow,False,True,0,0.249,0.316,-0.219
 xgb,medium,True,True,0,0.239,0.308,-0.163
 lgb,medium,True,True,0,0.238,0.303,-0.119
 xgb,shallow,True,False,3,0.248,0.317,-0.225
 lgb,shallow,True,False,3,0.218,0.282,0.032
 xgb,very-deep,True,False,0,0.261,0.327,-0.305

lgb,very-deep,True,False,0,0.212,0.272,0.093
 xgb,deep,True,True,4,0.23,0.295,-0.065
 lgb,deep,True,True,4,0.241,0.308,-0.162
 xgb,very-deep,False,False,2,0.252,0.321,-0.258
 lgb,very-deep,False,False,2,0.284,0.363,-0.606
 xgb,medium,True,True,3,0.234,0.3,-0.099
 lgb,medium,True,True,3,0.234,0.298,-0.088
 xgb,very-deep,True,False,2,0.245,0.312,-0.186
 lgb,very-deep,True,False,2,0.221,0.286,0.002
 xgb,deep,False,False,0,0.257,0.326,-0.297
 lgb,deep,False,False,0,0.265,0.338,-0.394
 xgb,shallow,False,True,2,0.325,0.397,-0.928
 lgb,shallow,False,True,2,0.295,0.365,-0.628
 xgb,medium,True,False,3,0.269,0.34,-0.411
 lgb,medium,True,False,3,0.243,0.313,-0.2
 xgb,very-deep,False,True,2,0.282,0.349,-0.492
 lgb,very-deep,False,True,2,0.268,0.338,-0.395
 xgb,deep,True,True,0,0.222,0.287,-0.009
 lgb,deep,True,True,0,0.22,0.284,0.013
 xgb,medium,False,False,0,0.263,0.336,-0.377
 lgb,medium,False,False,0,0.269,0.34,-0.416
 xgb,medium,False,True,2,0.286,0.353,-0.526
 lgb,medium,False,True,2,0.268,0.337,-0.389
 xgb,deep,False,False,4,0.251,0.321,-0.259
 lgb,deep,False,False,4,0.283,0.356,-0.55
 xgb,shallow,True,True,2,0.248,0.316,-0.216
 lgb,shallow,True,True,2,0.218,0.285,0.008
 xgb,shallow,False,False,4,0.28,0.35,-0.496
 lgb,shallow,False,False,4,0.273,0.348,-0.476
 xgb,very-deep,False,True,4,0.273,0.341,-0.421
 lgb,very-deep,False,True,4,0.277,0.345,-0.458
 xgb,shallow,True,True,3,0.287,0.363,-0.61
 lgb,shallow,True,True,3,0.222,0.285,0.007
 xgb,shallow,False,True,3,0.297,0.365,-0.625
 lgb,shallow,False,True,3,0.255,0.322,-0.264
 xgb,medium,False,False,2,0.263,0.334,-0.361
 lgb,medium,False,False,2,0.265,0.339,-0.406
 xgb,very-deep,True,True,3,0.224,0.29,-0.026
 lgb,very-deep,True,True,3,0.227,0.296,-0.072
 xgb,medium,True,True,4,0.241,0.311,-0.182
 lgb,medium,True,True,4,0.227,0.297,-0.078

xgb,deep,True,False,0,0.252,0.317,-0.229
 lgb,deep,True,False,0,0.216,0.276,0.069
 xgb,deep,False,False,2,0.243,0.31,-0.175
 lgb,deep,False,False,2,0.272,0.348,-0.483
 xgb,medium,False,True,4,0.267,0.335,-0.373
 lgb,medium,False,True,4,0.289,0.36,-0.583
 xgb,very-deep,False,True,3,0.266,0.335,-0.374
 lgb,very-deep,False,True,3,0.261,0.328,-0.317
 xgb,very-deep,True,True,4,0.229,0.295,-0.062
 lgb,very-deep,True,True,4,0.243,0.309,-0.164
 xgb,very-deep,True,True,0,0.217,0.282,0.029
 lgb,very-deep,True,True,0,0.217,0.282,0.028
 xgb,medium,False,False,4,0.264,0.334,-0.363
 lgb,medium,False,False,4,0.285,0.356,-0.551
 xgb,medium,True,True,2,0.22,0.283,0.02
 lgb,medium,True,True,2,0.244,0.31,-0.174
 xgb,shallow,True,False,4,0.273,0.35,-0.497
 lgb,shallow,True,False,4,0.22,0.293,-0.052
 xgb,very-deep,True,True,2,0.227,0.291,-0.037
 lgb,very-deep,True,True,2,0.228,0.296,-0.073
 xgb,medium,True,False,0,0.261,0.328,-0.316
 lgb,medium,True,False,0,0.214,0.274,0.084
 xgb,deep,False,False,3,0.259,0.328,-0.317
 lgb,deep,False,False,3,0.286,0.362,-0.598
 xgb,very-deep,False,False,0,0.255,0.325,-0.289
 lgb,very-deep,False,False,0,0.262,0.334,-0.362

Anhang 2/2: Ergebnisse der Zufalls-Validierung

Modelltyp,Parametertiefe,Kategorisch,Aggregate,Smoothed,MAE,RMSE,R2
 xgb,shallow,True,True,0,0.285,0.358,0.193
 lgb,shallow,True,True,0,0.319,0.399,-0.0
 xgb,deep,False,True,4,0.186,0.243,0.628
 lgb,deep,False,True,4,0.269,0.336,0.292
 xgb,deep,True,False,2,0.276,0.352,0.219
 lgb,deep,True,False,2,0.299,0.373,0.126
 xgb,medium,False,True,3,0.177,0.234,0.654
 lgb,medium,False,True,3,0.257,0.321,0.352
 xgb,shallow,False,False,2,0.218,0.283,0.496
 lgb,shallow,False,False,2,0.27,0.334,0.3
 xgb,very-deep,False,True,0,0.176,0.234,0.657

lgb,very-deep,False,True,0,0.245,0.311,0.391
 xgb,medium,True,False,2,0.272,0.348,0.238
 lgb,medium,True,False,2,0.291,0.366,0.156
 xgb,deep,True,True,3,0.278,0.353,0.216
 lgb,deep,True,True,3,0.284,0.354,0.213
 xgb,deep,True,True,2,0.294,0.366,0.158
 lgb,deep,True,True,2,0.288,0.36,0.184
 xgb,medium,False,False,3,0.19,0.251,0.603
 lgb,medium,False,False,3,0.251,0.316,0.373
 xgb,shallow,False,True,4,0.198,0.257,0.584
 lgb,shallow,False,True,4,0.267,0.33,0.316
 xgb,shallow,False,False,0,0.225,0.291,0.468
 lgb,shallow,False,False,0,0.268,0.339,0.278
 xgb,shallow,True,True,4,0.333,0.407,-0.043
 lgb,shallow,True,True,4,0.298,0.375,0.117
 xgb,very-deep,False,False,3,0.184,0.244,0.625
 lgb,very-deep,False,False,3,0.26,0.324,0.341
 xgb,deep,True,False,3,0.277,0.354,0.213
 lgb,deep,True,False,3,0.304,0.377,0.107
 xgb,very-deep,True,False,3,0.283,0.361,0.18
 lgb,very-deep,True,False,3,0.295,0.367,0.152
 xgb,shallow,False,False,3,0.22,0.285,0.489
 lgb,shallow,False,False,3,0.282,0.349,0.233
 xgb,shallow,True,False,2,0.287,0.365,0.16
 lgb,shallow,True,False,2,0.304,0.381,0.085
 xgb,medium,True,False,4,0.273,0.359,0.191
 lgb,medium,True,False,4,0.295,0.37,0.138
 xgb,very-deep,True,False,4,0.287,0.37,0.138
 lgb,very-deep,True,False,4,0.301,0.375,0.115
 xgb,deep,False,True,2,0.179,0.237,0.646
 lgb,deep,False,True,2,0.259,0.326,0.332
 xgb,shallow,True,False,0,0.289,0.375,0.114
 lgb,shallow,True,False,0,0.3,0.375,0.114
 xgb,deep,True,False,4,0.278,0.36,0.183
 lgb,deep,True,False,4,0.305,0.382,0.08
 xgb,very-deep,False,False,4,0.195,0.26,0.574
 lgb,very-deep,False,False,4,0.263,0.325,0.335
 xgb,deep,False,True,0,0.182,0.243,0.628
 lgb,deep,False,True,0,0.23,0.294,0.458
 xgb,medium,False,True,0,0.188,0.248,0.612
 lgb,medium,False,True,0,0.255,0.323,0.342

xgb,deep,False,True,3,0.184,0.24,0.638
 lgb,deep,False,True,3,0.268,0.339,0.278
 xgb,shallow,False,True,0,0.193,0.253,0.597
 lgb,shallow,False,True,0,0.266,0.335,0.294
 xgb,medium,True,True,0,0.298,0.372,0.131
 lgb,medium,True,True,0,0.287,0.357,0.196
 xgb,shallow,True,False,3,0.295,0.373,0.123
 lgb,shallow,True,False,3,0.316,0.398,0.003
 xgb,very-deep,True,False,0,0.277,0.352,0.22
 lgb,very-deep,True,False,0,0.303,0.376,0.112
 xgb,deep,True,True,4,0.281,0.355,0.205
 lgb,deep,True,True,4,0.283,0.353,0.215
 xgb,very-deep,False,False,2,0.192,0.256,0.588
 lgb,very-deep,False,False,2,0.262,0.324,0.339
 xgb,medium,True,True,3,0.26,0.332,0.305
 lgb,medium,True,True,3,0.294,0.365,0.16
 xgb,very-deep,True,False,2,0.28,0.355,0.206
 lgb,very-deep,True,False,2,0.295,0.369,0.141
 xgb,deep,False,False,0,0.19,0.251,0.603
 lgb,deep,False,False,0,0.254,0.324,0.339
 xgb,shallow,False,True,2,0.196,0.256,0.589
 lgb,shallow,False,True,2,0.26,0.324,0.34
 xgb,medium,True,False,3,0.269,0.347,0.241
 lgb,medium,True,False,3,0.291,0.365,0.164
 xgb,very-deep,False,True,2,0.179,0.238,0.643
 lgb,very-deep,False,True,2,0.253,0.32,0.357
 xgb,deep,True,True,0,0.294,0.368,0.149
 lgb,deep,True,True,0,0.297,0.366,0.158
 xgb,medium,False,False,0,0.192,0.253,0.597
 lgb,medium,False,False,0,0.259,0.333,0.302
 xgb,medium,False,True,2,0.18,0.238,0.644
 lgb,medium,False,True,2,0.253,0.317,0.369
 xgb,deep,False,False,4,0.193,0.256,0.587
 lgb,deep,False,False,4,0.26,0.324,0.342
 xgb,shallow,True,True,2,0.372,0.461,-0.338
 lgb,shallow,True,True,2,0.303,0.376,0.112
 xgb,shallow,False,False,4,0.213,0.275,0.523
 lgb,shallow,False,False,4,0.285,0.348,0.24
 xgb,very-deep,False,True,4,0.187,0.25,0.608
 lgb,very-deep,False,True,4,0.259,0.325,0.336
 xgb,shallow,True,True,3,0.278,0.353,0.217

lgb,shallow,True,True,3,0.291,0.367,0.152
 xgb,shallow,False,True,3,0.199,0.261,0.571
 lgb,shallow,False,True,3,0.252,0.314,0.381
 xgb,medium,False,False,2,0.19,0.252,0.602
 lgb,medium,False,False,2,0.256,0.322,0.347
 xgb,very-deep,True,True,3,0.28,0.354,0.21
 lgb,very-deep,True,True,3,0.284,0.353,0.215
 xgb,medium,True,True,4,0.268,0.344,0.257
 lgb,medium,True,True,4,0.298,0.371,0.135
 xgb,deep,True,False,0,0.284,0.356,0.204
 lgb,deep,True,False,0,0.31,0.384,0.073
 xgb,deep,False,False,2,0.196,0.261,0.572
 lgb,deep,False,False,2,0.257,0.323,0.344
 xgb,medium,False,True,4,0.184,0.245,0.623
 lgb,medium,False,True,4,0.242,0.304,0.417
 xgb,very-deep,False,True,3,0.184,0.24,0.638
 lgb,very-deep,False,True,3,0.266,0.333,0.301
 xgb,very-deep,True,True,4,0.297,0.373,0.126
 lgb,very-deep,True,True,4,0.282,0.353,0.218
 xgb,very-deep,True,True,0,0.29,0.363,0.173
 lgb,very-deep,True,True,0,0.291,0.361,0.18
 xgb,medium,False,False,4,0.195,0.26,0.574
 lgb,medium,False,False,4,0.258,0.326,0.332
 xgb,medium,True,True,2,0.273,0.344,0.254
 lgb,medium,True,True,2,0.302,0.376,0.112
 xgb,shallow,True,False,4,0.31,0.398,0.005
 lgb,shallow,True,False,4,0.3,0.374,0.12
 xgb,very-deep,True,True,2,0.292,0.364,0.167
 lgb,very-deep,True,True,2,0.28,0.35,0.229
 xgb,medium,True,False,0,0.279,0.355,0.209
 lgb,medium,True,False,0,0.301,0.375,0.118
 xgb,deep,False,False,3,0.184,0.244,0.624
 lgb,deep,False,False,3,0.252,0.315,0.377
 xgb,very-deep,False,False,0,0.192,0.256,0.589
 lgb,very-deep,False,False,0,0.249,0.314,0.379

Literaturverzeichnis

- Bergstra, James; Bengio, Yoshua (2012):** Random Search for Hyper-Parameter Optimization. In: *Journal of Machine Learning Research* 13.10, S. 281–305.
- Borisov, Vadim et al. (2021):** Deep Neural Networks and Tabular Data: A Survey. In: *arXiv preprint arXiv:2110.01889*.
- Box, George E. P.; Jenkins, Gwilym M.; Reinsel, Gregory C.; Ljung, Greta M. (2015):** Time Series Analysis: Forecasting and Control. 5th. John Wiley & Sons. ISBN: 978-1118675021.
- Breiman, Leo (2001):** Random Forests. In: *Machine Learning* 45.1, S. 5–32. DOI: 10.1023/A:1010933404324.
- Chai, Tianfeng; Draxler, Roland R. (2014):** Root mean square error (RMSE) or mean absolute error (MAE)? Arguments against avoiding RMSE in the literature. In: *Geoscientific Model Development* 7, S. 1247–1250. DOI: 10.5194/gmd-7-1247-2014.
- Chen, Tianqi; Guestrin, Carlos (2016):** XGBoost: A Scalable Tree Boosting System. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, S. 785–794. DOI: 10.1145/2939672.2939785.
- Cleveland, William S. (1979):** Robust Locally Weighted Regression and Smoothing Scatterplots. In: *Journal of the American Statistical Association* 74.368, S. 829–836. DOI: 10.1080/01621459.1979.10481038.
- Döringer, Stefanie (2021):** 'The problem-centred expert interview'. Combining qualitative interviewing approaches for investigating implicit expert knowledge. In: *Geography and Regional Research*.
- Friedman, Jerome; Hastie, Trevor; Tibshirani, Robert (2009):** The Elements of Statistical Learning: Data Mining, Inference, and Prediction. 2nd. Springer.
- Friedman, Jerome H. (2001):** Greedy Function Approximation: A Gradient Boosting Machine. In: *Annals of Statistics* 29.5, S. 1189–1232. DOI: 10.1214/aos/1013203451.
- Goodfellow, Ian; Bengio, Yoshua; Courville, Aaron (2016):** Deep Learning. MIT Press. ISBN: 9780262035613.
- Gregor, Shirley; Jones, David (2007):** The Anatomy of a Design Theory. In: *Journal of the Association for Information Systems* 8.5, S. 312–335. DOI: 10.17705/1jais.00129.
- Guyon, Isabelle; Elisseeff, André (2003):** An Introduction to Variable and Feature Selection. In: *Journal of Machine Learning Research* 3, S. 1157–1182.
- Hall, Mark A. (1999):** Correlation-based Feature Selection for Machine Learning. Diss. Hamilton, New Zealand: University of Waikato, S. 51–103.
- Hastie, Trevor; Tibshirani, Robert; Friedman, Jerome (2009):** The Elements of Statistical Learning: Data Mining, Inference, and Prediction. 2nd. Springer, S. 587–590. ISBN: 978-0387848570.
- Hevner, Alan R.; March, Salvatore T.; Park, Jinsoo; Ram, Sudha (2004):** Design Science in Information Systems Research. In: *MIS Quarterly* 28.1, S. 75–105. DOI: 10.2307/25148625.

- Hodson, Timothy O. (2022):** Root-mean-square error (RMSE) or mean absolute error (MAE): when to use them or not. In: *Geoscientific Model Development* 15, S. 5481–5492. DOI: 10.5194/gmd-15-5481-2022.
- James, Gareth; Witten, Daniela; Hastie, Trevor; Tibshirani, Robert (2021):** An Introduction to Statistical Learning. 2nd. Springer. ISBN: 978-1071614174.
- Ke, Guolin; Meng, Qi; Finley, Thomas; Wang, Taifeng; Chen, Wei; Ma, Weidong; Ye, Qiwei; Liu, Tie-Yan (2017):** LightGBM: A Highly Efficient Gradient Boosting Decision Tree. In: *Proceedings of NIPS 2017*, S. 3146–3154.
- Kohavi, Ron (1995):** A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection. In: *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI-95)*. Montreal, Canada, S. 1137–1145.
- Kuhn, Max; Johnson, Kjell (2019):** Feature Engineering and Selection: A Practical Approach for Predictive Models. 1st. Chapman und Hall/CRC. DOI: 10.1201/9781315108230.
- McElfresh, Duncan; Khandagale, Sujay; Valverde, Jonathan; Prasad, Vishak; Feuer, Benjamin; Hegde, Chinmay; Ramakrishnan, Ganesh; Goldblum, Micah; White, Colin (2023):** When Do Neural Nets Outperform Boosted Trees on Tabular Data? In: *arXiv preprint arXiv:2305.02997*. URL: <https://arxiv.org/abs/2305.02997>.
- Mitchell, Thomas M. (1997):** Machine Learning. McGraw-Hill. ISBN: 0070428077.
- o. V. (2023):** LMDh-Reglement: Beginn einer neuen Ära im Langstrecken-Motorsport. URL: <https://newsroom.porsche.com/de/pressemappen/le-mans-2023/LMDh-Reglement--Beginn-einer-neuen-%C3%84ra-im-Langstrecken-Motorsport.html> (Abruf: 30.10.2025).
- o. V. (2024):** Gradient Boosting vs Random Forest. In: *GeeksforGeeks*. URL: <https://www.geeksforgeeks.org/machine-learning/gradient-boosting-vs-random-forest/>.
- o. V. (2025):** Classes: Le Mans Hypercar and LMDh. URL: <https://www.24h-lemans.com/en/lemans/classes> (Abruf: 30.10.2025).
- O'Donnell, James et al. (2024):** Determination of Multi-Component Failure in Automotive Applications. In: *Journal of Computing and Information Science in Engineering* 24.2. DOI: 10.1115/1.4063003.
- Pasaribu, J. (2024):** Tabular Data Classification and Regression. In: *IEEE Access* 12, S. 1–12.
- Pedregosa, Fabian; Varoquaux, Gaël; Gramfort, Alexandre; Michel, Vincent; Thirion, Bertrand; Grisel, Olivier; Blondel, Mathieu; Prettenhofer, Peter; Weiss, Ron; Dubourg, Vincent; Vanderplas, Jake; Passos, Alexandre; Cournapeau, David; Brucher, Mathieu; Perrot, Matthieu; Duchesnay, Édouard (2011):** Scikit-learn: Machine Learning in Python. In: *Journal of Machine Learning Research* 12, S. 2825–2830.
- Tukey, John Wilder (1977):** Exploratory Data Analysis. Addison-Wesley Publishing Company. ISBN: 0201076160.
- Venable, John R.; Pries-Heje, Jan; Baskerville, Richard L. (2016):** FEDS: A Framework for Evaluation in Design Science Research. In: *European Journal of Information Systems* 25.1, S. 77–89. DOI: 10.1057/ejis.2014.36.

- Willmott, Cort J.; Matsuura, Kenji (2005):** Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance. In: *Climate Research* 30.1, S. 79–82. DOI: 10.3354/cr030079.
- Yu, Lei; Liu, Huan (2004):** Efficient Feature Selection via Analysis of Relevance and Redundancy. In: *Journal of Machine Learning Research* 5.October, S. 1205–1224.

Erklärung zur Verwendung generativer KI-Systeme

Bei der Erstellung der eingereichten Arbeit habe ich auf künstlicher Intelligenz (KI) basierte Systeme benutzt:

☒ ja

Falls ja: Die nachfolgend aufgeführten auf künstlicher Intelligenz (KI) basierten Systeme habe ich bei der Erstellung der eingereichten Arbeit benutzt:

1. Perplexity
2. Google Gemini

Ich erkläre, dass ich

- mich aktiv über die Leistungsfähigkeit und Beschränkungen der oben genannten KI-Systeme informiert habe,
- die aus den oben angegebenen KI-Systemen direkt oder sinngemäß übernommenen Passagen gekennzeichnet habe,
- überprüft habe, dass die mithilfe der oben genannten KI-Systeme generierten und von mir übernommenen Inhalte faktisch richtig sind,
- mir bewusst bin, dass ich als Autorin bzw. Autor dieser Arbeit die Verantwortung für die in ihr gemachten Angaben und Aussagen trage.

Die oben genannten KI-Systeme habe ich wie im Folgenden dargestellt eingesetzt:

Arbeitsschritt in der wissenschaftlichen Arbeit	Eingesetzte(s) KI-System(e)	Beschreibung der Verwendungsweise
Quellen Recherche	Perplexity	Unterstützung bei der Literatursuche und -analyse
Erstellung Fließtext	Perplexity, Google Gemini	Unterstützung bei der sprachlichen Ausformulierung

(Ort, Datum)

(Unterschrift)

Erklärung

Ich versichere hiermit, dass ich die vorliegende Arbeit mit dem Thema: *Fahrzeugbalance-Vorhersage im Motorsport: Entwicklung und Evaluation von Gradient-Boosting-Modellen auf Basis von Porsche LMDh Telemetriedaten* selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Ich versichere zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.

(Ort, Datum)

(Unterschrift)